PROBABILIDADE BÁSICA

THIAGO RAMOS & VINÍCIUS NOVELLI

1. A linguagem básica da probabilidade

Definição 1. Um *espaço de probabilidade* é um espaço de medida (Ω, Σ, μ) com a propriedade $\mu(\Omega) = 1$. O conjunto Ω é o *espaço amostral*, e um *evento* é uma classe de equivalência $[A]$ de $A \in \Sigma$ (onde $A, B \in \Sigma$ são equivalentes se $\mu(A \Delta B) = 0$). Se A for um evento em Ω, denotamos $\mu(A)$ por $\mathbb{P}(A)$.

Definição 2. Uma *variável aleatória* no espaço de probabilidade (Ω, Σ, μ) é uma função μ-mensurável $X : \Omega \to \mathbb{R}$.

Se $X \in L^1(X, \mu)$, dizemos que

$$\mathbb{E}(X) := \int_\Omega X(w) d\mu(w)$$

é a *esperança* (ou *média*) de X. É claro que se $X \geq 0$ for uma variável aleatória, também podemos definir sua esperança (que agora pode ser infinita). Se $\mathbb{E}(X^2) < \infty$ (note que por Cauchy-Schwarz isto implica que $|\mathbb{E}(X)| \leq \sqrt{\mathbb{E}(X^2)}$), definimos a *variância* de X por

$$\mathbb{V}\mathrm{ar}(X) := \mathbb{E}\left\{X - \mathbb{E}(X)\right\}^2 = \mathbb{E}(X^2) - \left(\mathbb{E}(X)\right)^2.$$

Neste caso, o *desvio padrão* de X é $\sigma_X = \sqrt{\mathbb{V}\mathrm{ar}(X)}$.

Definição 3. Se X é uma variável aleatória no espaço de probabilidade (X, Σ, μ), a sua *função distribuição de probabilidade* (fdp) é dada por

$$F_X(x) = \mathbb{P}(X \leq x) = \mu\{w \in \Omega;\ X(w) \leq x\}.$$

Observação 4. Observe que F_X é não-decrescente ($x \leq y \implies F_X(x) \leq F_X(y)$), contínua pela direita, além de satisfazer

$$\lim_{x \to -\infty} F_X(x) = 0 \quad \text{e} \quad \lim_{x \to \infty} F_X(x) = 1.$$

Note que neste caso F induz uma medida de Lebesgue-Stieltjes na σ-álgebra de Lebesgue de $\mathbb{R}$, que chamamos de μ_X (a *densidade de probabilidade* de X). Observe que esta medida é apenas o push-forward da medida μ em Ω para $\mathbb{R}$, via a aplicação mensurável X.

Vamos provar agora um lema que será útil no cálculo de vários modelos.

Lema 5. *Seja $X : \Omega \to \mathbb{R}$ uma variável aleatória, com densidade de probabilidade μ_X. Então, μ_X é uma medida de probabildade em $\mathbb{R}$, e se $f : \mathbb{R} \to \mathbb{R}$ é Lebesgue-mensurável, então*

$$\int_\mathbb{R} f(x) d\mu_X(x) = \int_\Omega (f \circ X)(w) d\mu(w).$$

Demonstração. Note que

$$\mu_X(\mathbb{R}) = F_X(\infty) - F_X(-\infty) = \mathbb{P}(X \leq \infty) = 1,$$

onde F_X é a fdp de X. Já para a identidade das integrais, note que se $f = \chi_E$, para $E \subset \mathbb{R}$ Lebesgue-mensurável, então

$$\int_{\mathbb{R}} f(x) d\mu_X(x) = \mu_X(E) = \mu(\chi_{X^{-1}(E)}) = \int_{\Omega} (f \circ X) d\mu.$$

De fato, note que $\mu_X(-\infty, x] = \mathbb{P}(X \leq x) = \mu\{w \in \Omega; X(w) \leq x\}$. Assim, obtemos $\mu_X(a, b] = \mu\{w \in W; a < X(w) \leq b\}$, e portanto o fato é válido para borelianos. Usando um argumento de densidade, obtemos o fato para todo E Lebesgue-mensurável, e aproximando f por combinações lineares de funções características, concluímos a prova do lema. □

Observação 6. Se X for uma variável aleatória tal que $d\mu_X = f(x)dx$ para alguma f mensurável (na prática, este é o caso mais comum), então

$$\mathbb{E}(X) = \int_{\Omega} X(w) d\mu(w) = \int_{\Omega} (f \circ X) d\mu(w),$$

onde $f : \mathbb{R} \to \mathbb{R}$ é $f(x) = x$. Assim, o lema mostra que

$$\mathbb{E}(X) = \int_{\mathbb{R}} x d\mu_X(x) = \int_{\mathbb{R}} x f(x) dx.$$

Já para a variância, temos

$$\mathbb{V}\mathrm{ar}(X) = \int_{\Omega} X^2(w) d\mu(w) - \mathbb{E}^2(X) = \int_{\Omega} (g \circ X)(w) d\mu(w) - \mathbb{E}^2(X),$$

onde $g(x) = x^2$. Novamente, usando o lema, segue que

$$\mathbb{V}\mathrm{ar}(X) = \int_{\mathbb{R}} x^2 f(x) dx - \left(\int_{\mathbb{R}} x f(x) dx \right)^2$$

Assim, para sabermos informações da variável aleatória (como sua esperança ou variância), basta conhecermos a sua densidade de probabilidade! Isto será útil para calcularmos alguns modelos contínuos.

Façamos agora uma lista dos modelos básicos usados em probabilidade.

(1) **(Distribuição de Bernoulli)** Neste caso, a variável aleatória que consideramos é da forma $X : \Omega \to \{0, 1\}$, onde $\mathbb{P}(X = 1) = p$ e $\mathbb{P}(X = 0) = 1 - p$, para algum $p \in [0, 1]$. Obtemos

$$\mathbb{E}(X) = p \quad \text{e} \quad \mathbb{V}\mathrm{ar}(X) = p - p^2 = p(1 - p).$$

(2) **(Distribuição binomial)** Dados dois parâmetros, $n \geq 1$ e $p \in [0, 1]$, a variável aleatória é $X : \Omega \to \{0, \ldots, n\}$, satisfazendo

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}.$$

Para calcular a esperança, observe que

$$\begin{aligned}
\mathbb{E}(X) &= \sum_{k=0}^{n} k \binom{n}{k} p^k (1-p)^{n-k} \\
&= np \sum_{k=1}^{n} \frac{(n-1)!}{((n-1)-(k-1))!(k-1)!} p^{k-1} (1-p)^{(n-1)-(k-1)} \\
&= np \sum_{j=0}^{n-1} \binom{n-1}{j} p^j (1-p)^{n-1-j} \\
&= np(p + (1-p))^{n-1} = np.
\end{aligned}$$

Já para a variância de X, basta notar que, usando o cálculo anterior,

$$\begin{aligned}
\mathbb{V}\mathrm{ar}(X) &= \sum_{k=0}^{n} k^2 \binom{n}{k} p^k (1-p)^{n-k} - (np)^2 \\
&= np \sum_{j=0}^{n-1} (j+1) \binom{n-1}{j} p^j (1-p)^{n-1-j} - (np)^2 \\
&= np((n-1)p + 1) - (np)^2 = np(1-p).
\end{aligned}$$

(3) **(Distribuição geométrica)** Esta distribuição possui um parâmetro $p \in (0, 1]$. A variável aleatória é $X : \Omega \to \mathbb{N}$, que satisfaz

$$\mathbb{P}(X = k) = p(1-p)^{k-1}.$$

Então,

$$\begin{aligned}
\mathbb{E}(X) = p \sum_{k=1}^{\infty} k(1-p)^{k-1} = p \sum_{k=1}^{\infty} \frac{\mathrm{d}}{\mathrm{d}x}\bigg|_{x=1-p} x^k &= p \frac{\mathrm{d}}{\mathrm{d}x}\bigg|_{x=1-p} \left(\frac{x}{1-x} \right) \\
&= \frac{p}{p^2} = \frac{1}{p}
\end{aligned}$$

Já para a variância, fazemos um cálculo similar,

$$\begin{aligned}
\mathbb{V}\mathrm{ar}(X) = p \sum_{k=1}^{\infty} k^2 (1-p)^{k-1} - p^{-2} &= p \sum_{k=1}^{\infty} k \left(\frac{\mathrm{d}}{\mathrm{d}x}\bigg|_{x=1-p} x^k \right) - p^{-2} \\
&= p \frac{\mathrm{d}}{\mathrm{d}x}\bigg|_{x=1-p} \left\{ x \sum_{k=1}^{\infty} k x^{k-1} \right\} - p^{-2} \\
&= p \frac{\mathrm{d}}{\mathrm{d}x}\bigg|_{x=1-p} \left(\frac{x}{(1-x)^2} \right) - p^{-2} \\
&= p \frac{p^2 + 2p(1-p)}{p^4} - p^{-2} \\
&= \frac{1-p}{p^2}.
\end{aligned}$$

(4) **(Distribuição de Poisson)** Esta distribuição possui um parâmetro $\lambda \in (0, \infty)$. A variável aleatória é $X : \Omega \to \mathbb{N} \cup \{0\}$, que satisfaz

$$\mathbb{P}(X = k) = \lambda^k \frac{e^{-\lambda}}{k!}.$$

Para determinarmos a esperança, fazemos

$$\mathbb{E}(X) = e^{-\lambda} \sum_{k=0}^{\infty} \frac{k\lambda^k}{k!} = \lambda e^{-\lambda} \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = \lambda.$$

Para a variância,

$$\begin{aligned} \mathbb{V}\mathrm{ar}(X) = e^{-\lambda} \sum_{k=0}^{\infty} k^2 \frac{\lambda^{-k}}{k!} - \lambda^2 &= \lambda e^{-\lambda} \sum_{j=0}^{\infty} (j+1) \frac{\lambda^j}{j!} - \lambda^2 \\ &= \lambda^2 + \lambda - \lambda^2 = \lambda. \end{aligned}$$

(5) **(Distribuição normal)** Esta distribuição tem dois parâmetros reais, μ e σ, e é comumente denotada por $N(\mu, \lambda)$, a *distribuição normal de média μ e desvio padrão σ*. Neste caso, descrevemos apenas a densidade de probabilidade, que é absolutamente contínua com relação à Lebesgue e dada por

$$d\mu_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx.$$

Como vimos no início, podemos calcular a esperança de X por

$$\mathbb{E}(X) = \int_{\mathbb{R}} x d\mu_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\infty} x \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx = \mu,$$

onde usamos o Wolfram-Alpha no cálculo desta integral. Para a variância, novamente usamos a observação do início do texto:

$$\mathbb{V}\mathrm{ar}(X) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\infty} x^2 \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx - \mu^2 = \sigma^2,$$

novamente, graças ao Wolfram-Alpha.

(6) **(Distribuição exponencial)** Esta distribuição possui um parâmetro $\lambda > 0$. Novamente, definimos apenas sua densidade de probabilidade, que é dada por

$$d\mu_X(x) = \lambda \chi_{[0,\infty)}(x) e^{-\lambda x} dx.$$

A esperança é dada por

$$\mathbb{E}(X) = \lambda \int_0^{\infty} x e^{-\lambda x} dx = \frac{\lambda}{\lambda^2} = \lambda^{-1}.$$

Já a variância é dada por

$$\mathbb{V}\mathrm{ar}(X) = \lambda \int_0^{\infty} x^2 e^{-\lambda x} dx - \lambda^{-2} = \frac{2}{\lambda^2} - \lambda^{-2} = \lambda^{-2}.$$

Tratemos agora de independência (ou morte)!

Definição 7. Dois eventos A, B em (Ω, Σ, μ) são *independentes* se

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Analogamente, k eventos $A_1, \ldots, A_k$ em (Ω, Σ, μ) são *mutuamente independentes* se para qualquer escolha de l índices distintos $\{j_1, \ldots, j_l\}$ em $\{1, \ldots, n\}$, valer

$$\mathbb{P}(A_1 \cap \ldots \cap A_l) = \prod_{q=1}^{l} \mathbb{P}(A_q).$$

Duas variáveis aleatórias X, Y em (Ω, Σ, μ) são *independentes* se, para todos $A, B \subset \mathbb{R}$ borelianos, tivermos $X^{-1}(A)$ e $Y^{-1}(B)$ eventos independentes. Uma coleção $\{X_1, \ldots, X_n\}$ de variáveis aleatórias é *mutuamente independente* se para toda família de de borelianos $A_1, \ldots, A_k \subset \mathbb{R}$, os eventos $X_i^{-1}(A_i)$ forem mutuamente independentes. Se, além disso, as densidades μ_{X_i} forem as mesmas, dizemos que as X_i são *independentes e idênticamente distribuídas* (iid).

Proposição 8. *Sejam $X_1, \ldots, X_k$ variáveis aleatórias. Então, existe uma única medida $\mu_{X_1,\ldots,X_k}$ em $\mathbb{R}^k$ tal que para todas $f_1, \ldots, f_k : \mathbb{R} \to \mathbb{R}$ funções mensuráveis e limitadas, vale*

$$\mathbb{E}\left(f_1(X_1) \cdot \ldots \cdot f_k(X_k)\right) = \int_{\mathbb{R}^k} f_1(x_1) \ldots f_k(x_k) d\mu_{X_1,\ldots,X_k}(x_1, \ldots, x_k).$$

Esta medida é chamada de probabilidade conjunta de $X_1, \ldots, X_k$.

Demonstração. Observe que a fórmula implica que, tomando $f_i = \chi_{E_i}$ como função característica de um Lebesgue-mensurável $E_i \subset \mathbb{R}$, temos

$$\int_\Omega \prod_{i=1}^{k} \chi_{X_i^{-1}(E_i)} d\mu = \mu_{X_1,\ldots,X_k}(E_1 \times \ldots \times E_k),$$

ou seja, definimos

$$\mu_{X_1,\ldots,X_k}\left(E_1 \times \ldots \times E_k\right) = \mu\left(X_1^{-1}(E_1) \cap \ldots \cap X_k^{-1}(E_k)\right).$$

(observe que se as variáveis fossem independentes, isto seria o produto de $\mu_{X_i}(E_i)$, e portanto a medida $\mu_{X_1,\ldots,X_k}$ neste caso é apenas a medida produto $\mu_{X_1} \times \ldots \times \mu_{X_k}$). Se $E_1 \times \ldots \times E_k$ for reunião (finita ou enumerável) de retângulos disjuntos $E_1^j \times \ldots \times E_k^j$, então

$$\prod_{j=1}^{n} \chi_{X_i^{-1}(E_i)} = \sum_j \prod_{i=1}^{n} \chi_{X_i^{-1}(E_i^j)}.$$

De fato, $\prod_{j=1}^{n} \chi_{X_i^{-1}(E_i)} = \chi_{\cap_{i=1}^{n} X_i^{-1}(E_i)}$, enquanto o lado direito vale $\sum_j \chi_{\cap_{i=1}^{n} X_i^{-1}(E_i^j)}$. Assim, a função que definimos nos retângulos $E_1 \times \ldots \times E_k$ é de fato uma pré-medida nesta álgebra, e portanto induz uma medida exterior, que quando restrita à σ-álgebra gerada por estas caixas (a σ-álgebra de Lebesgue em $\mathbb{R}^k$), nos dá uma medida. A fórmula indicada segue do argumento de aproximação usual, já que ela envolve apenas funções do tipo $f_1(x_1) \ldots f_k(x_k)$. A unicidade segue do fato de que duas medidas que satisfazem aquela equação terem que ser iguais como pré-medidas na álgebra dos retângulos, e como a pré-medida $\mu_{X_1,\ldots,X_k}$ em $\mathbb{R}^k$ é σ-finita (de fato, finita), a extensão a esta σ-álgebra é única. $\square$

Agora vamos definir funções características de variáveis aleatórias.

Definição 9. Seja X uma variável aleatória. Então, a *função característica* de X, denotada por $\phi_X(t)$, é dada por

$$\phi_X(t) = \mathbb{E}(e^{itX}).$$

Observe que esta função característica de X permite calcular a esperança de $f(X)$, para $f : \mathbb{R} \to \mathbb{R}$ com $\widehat{f} \in L^1$. De fato, (a normalização que usamos para a transformada de Fourier é $\widehat{f}(x) = (2\pi)^{-1/2} \int e^{-itx} f(t)dt$), pela fórmula da inversão de Fourier,

$$\begin{aligned} f(x) = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} \widehat{f}(t) e^{ixt} dt \implies \mathbb{E}(f(X)) &= \int_{\Omega} f \circ X d\mu \\ &= \int_{\Omega} \left\{ \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{itX(w)} \widehat{f}(t) dx \right\} d\mu(w) \\ &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} \widehat{f}(t) \left\{ \int_{\Omega} e^{itX(w)} d\mu(w) \right\} dt \\ &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} \widehat{f}(t) \phi_X(t) dt, \end{aligned}$$

onde a aplicação do teorema de Fubini é justificada pois $e^{itX(w)}\widehat{f}(t)$ é integrável na medida $d\mu \times dt$ pois $\widehat{f}$ está em L^1, $\left|e^{itX(w)}\right| = 1$ e μ é finita.

Outra coisa interessante é que se duas variáveis aleatórias, X e Y, tiverem as mesmas funções características $\phi_X = \phi_Y$, então X e Y têm as mesmas densidades de probabilidade. Isto segue do lema 5, pois vamos ter

$$\int_{\mathbb{R}} f(x) d\mu_X(x) = \int_{\mathbb{R}} f(x) d\mu_Y(x),$$

para toda f com $\widehat{f} \in L^1$. Mas estas funções são densas no espaço das funções contínuas de suporte compacto, logo as medidas devem ser iguais necessariamente.

Proposição 10. *Se $\mathbb{E}(|X|) < \infty$, então $\phi_X(t)$ é de classe C^1, e*

$$\left.\frac{d}{dt}\phi_X(t)\right|_{t=0} = i\mathbb{E}(X).$$

Se $\mathbb{E}(|X|^k) < \infty$, então $\phi_X(t)$ é de classe C^k, e para todo $j = 1, \ldots, k$, temos

$$\frac{d^j}{dx^j}\phi_X(t) = i^j \mathbb{E}(X^j e^{itX}).$$

Se $k = 2$, temos

$$\phi_X(t) = 1 + it\mathbb{E}(X) - \frac{t^2}{2}\left(\mathbb{V}ar(X) + \mathbb{E}^2(X)\right) + o(t^2)$$

quando $t \to 0$.

Demonstração. Suponha que $\mathbb{E}(|X|) < \infty$. Então, dado $t \in \mathbb{R}$ e h pequeno,

$$\frac{1}{h}\left(\phi_X(t+h) - \phi_X(t)\right) = \int_{\Omega} e^{itX(w)} \left\{ \frac{e^{ihX(w)} - 1}{h} \right\} d\mu(w).$$

Pelo teorema da convergência dominada, fazendo $h \to 0$, obtemos

$$\phi'_X(t) = i \int_{\Omega} e^{itX(w)} X(w) d\mu(w),$$

que depende continuamente de t por mais uma aplicação do teorema da convergência dominada. Se soubéssemos que $\mathbb{E}(|X|^2) < \infty$, poderíamos repetir este cálculo e obter

$$\phi_X''(t) = i^2 \int_\Omega e^{itX(w)} X^2(w) d\mu(w) = -\left(\mathbb{V}\mathrm{ar}(X) + \mathbb{E}(X)^2\right).$$

A proposição está provada. □

Outra propriedade interessante das funções características é que, se X e Y forem independentes, então

$$\phi_{X+Y}(t) = \phi_X(t)\phi_Y(t).$$

Isto segue da proposição 8 e do fato de $d\mu_{X,Y} = d\mu_X \times d\mu_Y$.

A seguir calculamos alguns exemplos:

(1) **(Distribuição de Bernoulli)** Seja X uma variável aleatória com valores ± 1 e probabilidade $1/2$, é fácil ver que

$$\phi_X(t) = \cos t.$$

(2) **(Distribuição binomial)** Seja X uma variável aleatória com distribuição binomial, então

$$\begin{aligned} \phi_X(t) &= \textstyle\sum_{k=0}^n \binom{n}{k} e^{itk} p^k (1-p)^{n-k} = \sum_{k=0}^n \binom{n}{k} (pe^{it})^k (1-p)^{n-k} \\ &= (pe^{it} + (1-p))^n \end{aligned}$$

(3) **(Distribuição geométrica)**Seja X uma variável aleatória com distribuição geométrica, então

$$\begin{aligned} \phi_X(t) &= p \sum_{k=1}^\infty e^{itk} (1-p)^{k-1} = pe^{it} \sum_{k=1}^\infty e^{it(k-1)} (1-p)^{k-1} \\ &= pe^{it} \sum_{k=1}^\infty [e^{it}(1-p)]^{k-1} = \frac{pe^{it}}{1-(1-p)e^{it}} \end{aligned}$$

(4) **(Distribuição de Poisson)** Seja X uma variável aleatória com distribuição de Poisson com parâmetro $\lambda \in (0,1)$, então

$$\phi_X(t) = e^{-\lambda} \sum_{k=0}^\infty \frac{e^{itk}\lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^\infty \frac{[e^{it}\lambda]^k}{k!} = e^{-\lambda} e^{\lambda e^{it}} = e^{\lambda(e^{it}-1)}$$

(5) **(Distribuição normal)** Seja X uma variável aleatória com distribuição normal $N(\mu, \lambda)$. Então, utilizando a regra da substituição algumas vezes, e lembrando que a integral gaussiana satisfaz $\int_{-\infty}^\infty e^{-x^2} dx = \sqrt{\pi}$, temos que

$$\phi_X(t) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^\infty \exp(itx) \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx = e^{i\mu t - \sigma^2 t/2} \ .$$

(6) **(Distribuição exponencial)** Seja X uma variável aleatória com distribuição exponencial com parâmetro $\lambda > 0$, então

$$\phi_X(t) = \lambda \int_0^\infty e^{itx} e^{-\lambda x} dx = \lambda \frac{e^{x(it-\lambda)}}{it-\lambda}\Big|_0^\infty = \frac{\lambda}{\lambda - it}.$$

2. Convergência

Falemos agora de tipos de convergência de variáveis aleatórias.

Definição 11. Sejam $(X_n)_{n=1}^\infty$ uma sequência de variáveis aleatórias e X_∞ uma variável aleatória. Dizemos que

(1) $X_n \xrightarrow{\text{d}} X_\infty$, ou seja, X_n converge a X_∞ *em distribuição* se para toda função $f : \mathbb{R} \to \mathbb{R}$ contínua de suporte compacto, temos

$$\mathbb{E}\left(f(X_n)\right) \to \mathbb{E}\left(f(X_\infty)\right).$$

(2) $X_n \xrightarrow{\text{p}} X_\infty$, ou seja, X_n converge a X_∞ *em probabilidade* se para todo $\varepsilon > 0$,

$$\mathbb{P}\left(|X_n - X_\infty| > \varepsilon\right) \to 0.$$

(3) $X_n \xrightarrow{\text{qs}} X_\infty$, ou seja, X_n converge a X_∞ *quase sempre* se, para quase todo $w \in \Omega$,

$$X_n(w) \to X_\infty(w).$$

Observação 12. Defina $\mathbb{R}_\infty = \mathbb{R} \cup \{\infty\}$ a compactificação de um ponto de $\mathbb{R}$. Denote por $\mathcal{M}_{+,1}(\mathbb{R})$ o espaço das medidas de probabilidade em $\mathbb{R}$. Observe que temos a inclusão usual

$$\mathcal{M}_{+,1}(\mathbb{R}) \hookrightarrow \mathcal{M}_{+,1}(\mathbb{R}_\infty)$$

simplesmente declarando $\mu(\{\infty\}) = 0$. O espaço de todas as medidas de Radon em $\mathbb{R}_\infty$ é isométrico a $C(\mathbb{R}_\infty)^*$ pelo teorema da representação de Riesz, e portanto, possui a topologia fraca*. Assim, $X_n \xrightarrow{\text{d}} X_\infty$, significa que (pelo lema 5)

$$\int_{\mathbb{R}} f(t) d\mu_{X_n}(t) \to \int_{\mathbb{R}} f(t) d\mu_{X_\infty}(t).$$

Ou seja, convergir em distribuição é o mesmo que dizer que as densidades convergem na topologia fraca*.

Teorema 13 (Propriedades básicas das convergências)**.** *Sejam $(X_n)_{n=1}^\infty$ uma sequência de variáveis aleatórias e X_∞ uma variável aleatória. Então,*

(1) $X_n \xrightarrow{p} X_\infty \implies X_n \xrightarrow{d} X_\infty$.
(2) $X_n \xrightarrow{qs} X_\infty \implies X_n \xrightarrow{d} X_\infty$.
(3) *Se X_∞ for constante em quase todo ponto, então*

$$X_n \xrightarrow{d} X_\infty \implies X_n \xrightarrow{p} X_\infty.$$

Demonstração. Para o primeiro item, se $f \in C_c(\mathbb{R})$ é contínua de suporte compacto, então é uniformemente contínua. Dado $\varepsilon > 0$, seja $\delta > 0$ tal que $|x - y| \leq \delta \implies |f(x) - f(y)| \leq \varepsilon$. Como $X_n \to X_\infty$ em probabilidade, então

$$\mu\{w \in \Omega; |X_n(w) - X_\infty(w)| \geq \delta\} \to 0.$$

Assim,

$$\left|\int_\Omega (f\circ X_\infty - f\circ X_n)\,d\mu\right| \le \int_\Omega |f(X_\infty(w)) - f(X_n(w))|\,d\mu(w)$$
$$\le \varepsilon + 2(\sup|f|)\mu\{w\in\Omega; |X_n(w)-X_\infty(w)|\ge\delta\},$$

terminando a prova do primeiro item. O segundo item é uma consequência trivial do teorema da convergência dominada. Para o terceiro item, seja $X_\infty = c$ o valor de X_∞ q.t.p. Dado $\varepsilon > 0$, considere a função $f \in C_c(\mathbb{R})$ que vale 1 em $x = c$, 0 em $\mathbb{R}\backslash(c-\varepsilon, c+\varepsilon)$, e linear no resto. Então,

$$\mathbb{E}\left(f(X_\infty) - f(X_n))\right) = 1 - \int_{|X_n-c|\le\varepsilon} f(X_n)d\mu \ge 1 - \mathbb{P}(|X_n - c|\le\varepsilon) = \mathbb{P}(|X_n-c|>\varepsilon),$$

pois $f \le 1$. Isto termina a prova deste teorema. □

Teorema 14. *Sejam $(X_n)_{n=1}^\infty$ uma sequência de variáveis aleatórias e X_∞ uma variável aleatória. Então,*

(1) $X_n \xrightarrow{d} X_\infty$ *é induzida por uma métrica no espaço das medidas μ_X.*
(2) $X_n \xrightarrow{p} X_\infty$ *é induzida por uma métrica no espaço das variáveis aleatórias X_n.*

Demonstração. Note que, como $C(\mathbb{R}_\infty)$ é separável (pois $\mathbb{R}_\infty$ é compacto Hausdorff), a topologia fraca* na bola unitária é metrizável, e $\mathcal{M}_{1,0}(\mathbb{R})$ é um subconjunto da bola unitária (pois as medidas são de probabilidade). Já para o segundo item, podemos definir a métrica explicitamente:

$$\rho(X,Y) = \mathbb{E}(\min\{|X-Y|, 1\}).$$

É simples checar que esta métrica induz a convergência em probabilidade. □

Definição 15. Uma família de variáveis aleatórias $\{X_\alpha\}_{\alpha\in I}$ é *tight* se, para todo $\varepsilon > 0$, existe $R \in \mathbb{R}$ tal que

$$\mathbb{P}(|X_\alpha| > R) < \varepsilon$$

para todo $\alpha \in I$.

Teorema 16 (Teorema de Prokhorov)**.** *Uma família de densidades de probabilidade $\{d\mu_{X_\alpha}\}_{\alpha\in I}$ tem fecho compacto em $\mathcal{M}_{+,1}(\mathbb{R})$ se, e somente se, $\{X_\alpha\}_{\alpha\in I}$ é tight.*

Demonstração. Primeiramente vamos mostrar a volta. Suponha que $\{X_\alpha\}_{\alpha\in I}$ é tight. Utilizando a identificação da Observação 12, temos que o fecho de $\{d\mu_\alpha\}_{\alpha\in I}$ é compacto em $\mathcal{M}_{+,1}(\mathbb{R}_\infty)$, já que, pelo teorema de Banach-Alaoglu, a bola unitária do espaço métrico $\mathcal{M}_{+,1}(\mathbb{R}_\infty)$ é compacta. Logo, existe uma subsequência $\{d\mu_{X_{n_i}}\}_{i\in\mathbb{N}}$ e uma medida $\mu_\infty \in \mathcal{M}_{+,1}(\mathbb{R}_\infty)$ tal que

$$d\mu_{X_{n_i}} \to d\mu_\infty.$$

Então, se mostrarmos que $d\mu_\infty(\{\infty\}) = 0$, temos que $d\mu_\infty \in \mathcal{M}_{+,1}(\mathbb{R})$ e concluímos essa parte do teorema.
Como $\{X_\alpha\}_{\alpha\in I}$ é tight, dado $\varepsilon > 0$, existe $R > 0$ tal que, para todo $\alpha \in I$,

$$\mathbb{P}(|X_\alpha| > R) \le \varepsilon.$$

Considere então a função contínua e limitada f definida como $f(x) = 1$ se $|x| \le R$, $f(x) = 0$ se $|x| \ge R+1$ e linear no resto. Temos que

$$\int_{\mathbb{R}} f(t)d\mu_{X_{n_i}}(t) \geq \int_{[-R,R]} d\mu_{X_{n_i}} = \mu_{X_{n_i}}([-R,R]) = 1 - \mathbb{P}(|X_{n_i}| > R) \geq 1 - \varepsilon.$$

e portanto,

$$\int_{\mathbb{R}} f(t)d\mu_\infty(t) \geq 1 - \varepsilon.$$

Logo,

$$\mu_\infty(\{\infty\}) \leq \mu_\infty(\mathbb{R}\setminus\ [-R,R]) = 1 - \mu_\infty([-R,R]) \leq 1 - \int_\Omega f(t)d\mu_\infty(t)\ \leq \varepsilon.$$

Como $\varepsilon > 0$ foi arbitrário, temos o resultado.

Agora vamos mostrar que se $\{X_\alpha\}_{\alpha\in I}$ não é tight, então $\{d\mu_{X_\alpha}\}$ não tem fecho compacto em $\mathcal{M}_{+,1}(\mathbb{R})$.
Note que, se $\{X_\alpha\}_{\alpha\in I}$ não é tight, então existe $\varepsilon > 0$, tal que para todo $R > 0$, existe um $\alpha \in I$ de tal forma que

$$\mathbb{P}(|X_\alpha| > R) \geq \varepsilon,$$

e portanto, conseguimos uma sequência $\{X_n\}_{n\in\mathbb{N}}$ tal que

$$\mathbb{P}(|X_n| > n) \geq \varepsilon.$$

Considere, novamente, o conjunto compacto $\overline{\{d\mu_\alpha\}}_{\alpha\in I}$ em $\mathcal{M}_{+,1}(\mathbb{R}_\infty)$ e a sequência definida anteriormente $\{d\mu_{X_n}\}_{n\in\mathbb{N}}$. Então existe uma medida $\mu_\infty \in \mathcal{M}_{+,1}(\mathbb{R}_\infty)$ e uma subsequência tal que

$$d\mu_{X_{n_i}} \to d\mu_\infty$$

Mas observe que, então $\mu_\infty(\{\infty\}) \geq \varepsilon$, ou seja, essa sequência não admite subsequência convergente em $\mathcal{M}_{+,1}(\mathbb{R})$. Concluímos que $\{d\mu_\alpha\}_{\alpha\in I}$ não tem fecho compacto em $\mathcal{M}_{+,1}(\mathbb{R})$. □

Este teorema tem a seguinte consequência interessante.

Teorema 17. *Seja $\{X_n\}_{n=1}^\infty$ uma sequência de variáveis aleatórias. Então, existe um X_∞ com $X_n \xrightarrow{d} X_\infty$ se, e somente se*

(1) *$\{X_n\}_{n=1}^\infty$ é tight.*
(2) *Para todo $l = 1, 2, \ldots$, $\mathbb{E}\left\{(1+X_n^2)^{-l}\right\}$ e $\mathbb{E}\left\{X_n(1+X_n^2)^{-l}\right\}$ convergem.*

Demonstração. Façamos a implicação. Note que se $X_n \xrightarrow{\mathrm{d}} X_\infty$, então $\{d\mu_{X_n}\}_{n\in\mathbb{N}}$ tem fecho compacto em $\mathcal{M}_{+,1}(\mathbb{R})$, e pelo teorema de Prokhorov, a coleção $\{X_n\}_{n\in\mathbb{N}}$ é tight. Tome agora uma sequência $(f_m)_{m\in\mathbb{N}}$ de funções contínuas de suporte compacto com $f_m \to (1+x^2)^{-l}$, satisfazendo $f_m \leq f_{m+1} \leq (1+x^2)^{-1}$. Como a convergência é em distribuição, para cada $m \in \mathbb{N}$, vale

$$\mathbb{E}(f_m(X_n)) \xrightarrow{n\to\infty} \mathbb{E}(f_m(X_\infty)).$$

Pelo teorema de Fubini e o teorema da convergência dominada, obtemos

$$\mathbb{E}((1+X_n^2)^{-l}) \to \mathbb{E}((1+X_\infty^2)^{-l}).$$

Para a função $f(x) = x(1+x^2)^{-l}$, fazemos a mesma coisa. □

Teorema 18. *Sejam $(X_n)_{n=1}^{\infty}$ e X_∞ variáveis aleatórias e $a \in \mathbb{R}$ tal que $\mathbb{P}(X_\infty = a) = 0$. Então*

$$F_{X_n}(a) \xrightarrow{n\to\infty} F_{X_\infty}(a),$$

onde F_Y é a função de dsitribuição da variável aleatória Y. Reciprocamente, se $F_{X_n}(a) \xrightarrow{n\to\infty} F_{X_\infty}(a)$ para todo $a \in \mathbb{R}$ onde F_{X_∞} é contínua (com exceção possivelmente de um conjunto de medida nula), então $X_n \xrightarrow{d} X_\infty$.

Demonstração. Provemos inicialmente que

$$\mathbb{E}(f(X_n)) \to \mathbb{E}(f(X_\infty))$$

para toda f contínua em $\mathbb{R}$ com $f(x) = 0$ para $x > R_0$ e tal que $\lim_{x\to-\infty} f(x)$ existe. De fato, defina

$$f_R(x) = \begin{cases} f(x),\ x \geq -R \\ \theta,\ x = \theta(-R) + (1-\theta)(-R-1), \theta \in [0,1] \\ 0,\ x \leq -R-1 \end{cases}.$$

(ou seja, f_R é f para $x \geq -R$, 0 se $x \leq -R-1$, e linear em $[-R, -R-1]$). Assim, se Y é uma variável aleatória e R é arbitrário,

$$\mathbb{E}\left(|f(Y) - f_R(Y)|\right) \leq 2\|f\|_\infty \mathbb{P}(|Y| > R).$$

Como a família $\{X_n\}$ é tight, obtemos

$$\lim_{R\to\infty} \mathbb{E}(f_R(X_n)) = \mathbb{E}(f(X_n))$$

uniformemente em n (ou seja, $\mathbb{E}(f_R(X_n))$ fica perto de $\mathbb{E}(f(X_n))$ se R for grande independentemente de n). Agora, dado $\varepsilon > 0$, defina $f_\varepsilon^{\pm}$ como 1 antes do intervalo entre a e $a \pm \varepsilon$, 0 depois deste intervalo, e linearmente no intervalo. Então,

$$\int_{\mathbb{R}} f_\varepsilon^- d\mu_{X_n} \leq \int_{-\infty}^{a} d\mu_{X_n} \leq \int_{\mathbb{R}} f_\varepsilon^+ d\mu_{X_n},$$

ou seja,

$$\mathbb{E}(f_\varepsilon^-(X_n)) \leq F_{X_n}(a) \leq \mathbb{E}(f_\varepsilon^+(X_n)),$$

para cada n. Usando o que acabamos de provar, obtemos

$$\mathbb{E}(f_\varepsilon^-(X_\infty)) \leq \liminf F_{X_n}(a) \leq \limsup F_{X_n}(a) \leq \mathbb{E}(f_\varepsilon^+(X_\infty)).$$

Observe que $\mathbb{P}(X_\infty = a) = 0$ implica que F_{X_∞} é contínua em a, e já sabemos que $\mathbb{E}(f_\varepsilon^{\pm} t) \to F_{X_\infty}(a)$ quando $\varepsilon \to 0$. Isto termina o primeiro item. Para o segundo item, seja $f \in C_c^\infty(\mathbb{R})$. Então

$$\mathbb{E}(f(X)) = \int_{\mathbb{R}} f(x) d\mu_X(x) = -\int_{\mathbb{R}} f'(x) F_X(x) dx$$

pela fórmula de integral por partes da integral de Lebesgue-Stieltjes (um exercício fantástico que agradaria até o mais rodrigo dos thiago ramos). Assim, se $F_{X_n} \to F_{X_\infty}$, então pelo teorema da convergência dominada, $\mathbb{E}(f(X_n)) \to \mathbb{E}(f(X_\infty))$. Aproximando funções contínuas de suporte compacto por $C_c^\infty(\mathbb{R})$, obtemos o resultado. □

Corolário 19. *Para que X_n tenha limite em distribuição, é necessário e suficiente que $\{X_n\}$ seja tight e que $F_{X_n}(a)$ tenha um limite para quase todo $a \in \mathbb{R}$.*

3. Leis dos grandes números

Considere $\{X_n\}_{n=1}^{\infty}$ uma sequência de variáveis aleatórias i.i.d., e defina

$$S_n = X_1 + \ldots + X_n.$$

A lei dos grandes números diz que, sob hipóteses convenientes, S_n/n converge para a distribuição constante $X_\infty = \mathbb{E}(X_1)$. A lei *fraca* diz que esta convergência é em probabilidade, e a lei *forte* diz que esta convergência é quase sempre. A principal ferramente para demonstrar estes teoremas são os lemas de Borel-Cantelli, que descrevemos agora.

Lema 20 (Primeiro lema de Borel-Cantelli)**.** *Seja $(A_n)_{n=1}^{\infty}$ uma família de eventos em (Ω, Σ, μ), com a propriedade que*

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty.$$

Então,

$$\mathbb{P}\left(\limsup A_n\right) = 0.$$

Observação 21. O *limite superior* de uma sequência de conjuntos $(A_n)_{n=1}^{\infty}$ é o conjunto

$$\limsup A_n = \bigcap_{m=1}^{\infty} \bigcup_{n=m}^{\infty} A_n.$$

Em palavras, este é o conjunto de elementos $w \in \Omega$ que pertencem a uma infinidade de A_n's.

Demonstração. Seja χ_n a função característica de A_n. Pelo teorema da convergência monótona,

$$\mathbb{E}\left(\sum_{n=1}^{\infty} \chi_n\right) = \sum_{n=1}^{\infty} \mathbb{E}(\chi_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty.$$

Assim, $\sum_{n=1}^{\infty} \chi_n < \infty$ q.t.p. Mas

$$\left(\sum_{n=1}^{\infty} \chi_n\right)(w) < \infty$$

se, e somente se, w pertence apenas a um número finito dos A_n's. Assim, a probabilidade de w pertencer a apenas um número finito dos A_n's é 1, o que implica que

$$\mathbb{P}(\limsup A_n) = 0.$$

□

Lema 22 (Segundo lema de Borel-Cantelli)**.** *Se $(A_n)_{n=1}^{\infty}$ é uma sequência de eventos mutuamente independentes tal que*

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty,$$

então

$$\mathbb{P}(\limsup A_n) = 1.$$

Se os $(A_n)_{n=1}^{\infty}$ forem mutuamente independentes, obtemos a popular *lei 0-1 de Kolmogorov*, que diz que $\mathbb{P}(\limsup A_n)$ é 0 ou 1.

Demonstração. Seja $B_n = A_n^c$. Então

$$(\limsup A_n)^c = \bigcup_{m=1}^{\infty} \bigcap_{n=m}^{\infty} B_n.$$

Por independência, temos (observe que os B_n também são independentes)

$$\mathbb{P}\left(\bigcap_{m=n}^{\infty} B_n\right) = \prod_{m=1}^{\infty} \mathbb{P}(B_n) = \prod_{m=1}^{\infty} (1 - \mathbb{P}(A_n)) = 0$$

pois $\sum \mathbb{P}(A_n) = \infty$ (exercício). Isto mostra que $\mathbb{P}(\limsup A_n)^c = 0$, terminando a prova. □

Comecemos mostrando como provar a lei fraca dos grandes números.

Teorema 23 (Lei fraca dos grandes números)**.** *Seja $(X_n)_{n=1}^{\infty}$ uma sequência de variáveis aleatórias i.i.d, e suponha que $\mathbb{E}(X_1^2) < \infty$. Então,*

$$\frac{S_n}{n} := \frac{X_1 + \ldots + X_n}{n} \xrightarrow{p} \mathbb{E}(X_1).$$

Demonstração. Note que como as variáveis são identicamente distribuídas, $\mathbb{E}(X_1) = \mathbb{E}(X_j)$ para todo j. Assim, podemos trocar X_j por $X_j - \mathbb{E}(X_j)$ e supor sem perda de generalidade que $\mathbb{E}(X_j) = 0$ (note que translação de variáveis aleatórias idependentes ainda é independente). Assim, se $i \neq j$, pela proposição 8, temos

$$\mathbb{E}(X_i X_j) = \mathbb{E}(X_i)\mathbb{E}(X_j) = 0.$$

Assim, pela linearidade da esperança,

$$\mathbb{E}\left(S_n^2\right) = n\mathbb{E}(X_1^2).$$

Assim, dado $\varepsilon > 0$, seja χ a função característica do conjunto $\{w \in \Omega;\, n^{-1}|S_n| \geq \varepsilon\}$. Então, $\chi \leq \varepsilon^{-2} n^{-2} |S_n|^2$ em Ω, e integrando em Ω, obtemos

$$\mathbb{P}(n^{-1}|S_n| \geq \varepsilon) \leq \int_{\Omega} \frac{|S_n|^2}{n^2\varepsilon^2} d\mu = \frac{1}{n\varepsilon^2}\mathbb{E}(X_1^2),$$

que vai para zero quando $n \to \infty$. □

Observação 24. Este teorema é válido pedindo apenas $\mathbb{E}(|X_1|) < \infty$. Faremos isto em breve.

Proposição 25. *Seja $\{X_n\}_{n=1}^{\infty}$ uma sequência de variáveis aleatórias i.i.d e suponha que $\mathbb{E}(X_1) = 0$ e $\mathbb{E}(X_1^4) < \infty$. Então*

$$\mathbb{E}(S_n^4) = n\mathbb{E}(X_1^4) + 3n(n-1)\mathbb{E}(X_1^2)^2.$$

Demonstração. Utilizando a proposição 8, note que, como a sequência de eventos é i.i.d, então

$$\mathbb{E}(X_{i_1} X_{i_2} X_{i_3} X_{i_4}) \neq 0$$

somente se um dos casos acontece:

(I)	$i_1 = i_2 = i_3 = i_4$
(II)	$i_1 = i_2 \neq i_3 = i_4$
(III)	$i_1 = i_3 \neq i_2 = i_4$
(IV)	$i_1 = i_4 \neq i_2 = i_3$

Mas o caso (I) acontece n vezes, e os casos (II), (III) e (IV) acontecem $n(n-1)$ vezes cada um.

□

Teorema 26 (Lei forte dos grandes números)**.** *Seja $(X_n)_{n=1}^{\infty}$ uma sequência de variáveis aleatórias i.i.d, e suponha que $\mathbb{E}(X_1^2) < \infty$. Então,*

$$\frac{S_n}{n} := \frac{X_1 + \ldots + X_n}{n} \xrightarrow{qs} \mathbb{E}(X_1).$$

Demonstração. Vamos supor novamente que $\mathbb{E}(X_j) = 0$. Defina então a variável aleatória D_n dada por

$$D_n = \max_{n^2 \leq k < (n+1)^2} |S_k - S_{n^2}|.$$

É claro que,

$$D_n^2 \leq \sum_{k=n^2}^{(n+1)^2-1} (S_k - S_{n^2})^2.$$

Além disso, como já vimos na demonstração da Lei fraca dos grande números, temos que $\mathbb{E}(S_n^2) = nE(X_1)$ e portanto

$$\mathbb{E}((S_k - S_{n^2})^2) = \mathbb{E}(X_1^2)(k - n^2)$$

Logo,

$$\begin{aligned} \mathbb{E}(D_n^2) \quad &\leq \quad \sum_{k=n^2}^{(n+1)^2-1} \mathbb{E}((S_k - S_{n^2})^2) = \sum_{k=n^2}^{(n+1)^2-1} \mathbb{E}(X_1^2)(k - n^2) = \\ &= \quad \mathbb{E}(X_1^2) \sum_{k=1}^{2n} k = \mathbb{E}(X_1^2)(2n+1)n \end{aligned}$$

Agora, dado $\varepsilon > 0$, considere, χ a função característica do conjunto $\{w \in \Omega;\ |D_n| \geq \varepsilon n^2\}$. Então, $\chi \leq \dfrac{|D_n|^2}{n^4\varepsilon^2}$ em Ω, e portanto

$$\mathbb{P}(|D_n| \geq n^2\varepsilon) \leq \int_\Omega \frac{|D_n|^2}{n^4\varepsilon^2} d\mu \leq \frac{\mathbb{E}(X_1^2)n(2n+1)}{n^4\varepsilon^2}$$

Mas então

$$\sum_{n=1}^{\infty} \mathbb{P}(|D_n| \geq n^2\varepsilon) < \infty$$

e pelo primeiro lema de Borel-Cantelli, temos que

$$\mathbb{P}\left(\limsup(\{|D_n| \geq n^2\varepsilon)\}\right) = 0.$$

Logo, para quase todo $\omega \in \Omega$, eventualmente temos que $|D_n(\omega)| \leq n^2\varepsilon$ e portanto

$$\limsup_{n\to\infty} \left|\frac{D_n}{n^2}\right| \leq \varepsilon \quad \mu\text{-q.t.p. em } \Omega.$$

Escolhendo $\varepsilon = 1/k$ e fazendo intersecção enumerável destes conjuntos de medida total, obtemos

$$\limsup_{n\to\infty} \frac{D_n}{n^2} = 0 \quad \mu\text{-q.t.p. em } \Omega.$$

Também temos, como visto na demonstração da Lei fraca dos grandes números, que

$$\mathbb{P}(n^{-2}|S_{n^2}| \geq \varepsilon) \leq \int_\Omega \frac{|S_{n^2}|^2}{n^4\varepsilon^2} d\mu = \frac{1}{n^2\varepsilon^2}\mathbb{E}(X_1^2),$$

e então, usando o argumento que fizemos acima (com Borel-Cantelli), obtemos

$$\limsup_{m\to\infty} \left|\frac{S_{m^2}}{m^2}\right| = 0,$$

ou seja, $\lim_{m\to\infty} \dfrac{S_{m^2}}{m^2} = 0$ em quase todo ponto de Ω. No entanto, observe que se $k \geq n^2$,

$$|S_k| - |S_{n^2}| \leq |S_k - S_{n^2}| \leq D_n \implies |S_k| \leq |S_{n^2}| + D_n.$$

Portanto, (observe que $k^{-1} \leq n^{-2}$)

$$\frac{|S_k|}{k} \leq \frac{|S_k|}{n^2} \leq \frac{|S_{n^2}| + D_n}{n^2} \leq \sup_{m\geq n} \frac{|S_{m^2}| + D_m}{m^2}$$

Como o $k \geq n^2$ é qualquer, obtemos

$$\sup_{k\geq n^2} \frac{|S_k|}{k} \leq \sup_{m\geq n} \frac{|S_{m^2}| + D_m}{m^2} \xrightarrow{n\to\infty} 0$$

pois $\limsup_m m^{-2}|S_{m^2}| = \limsup_m m^{-2}D_m = 0$. Isto conclui a prova do resultado. □

O último tópico desta seção será a *lei do logaritmo iterado* para um passeio aleatório simples. Antes disso calcularemos $\limsup X_n/\sigma_n^2$, onde X_n são variáveis independentes com distribuição $N(0, \sigma_n)$. Para isto, precisamos de um lema.

Lema 27. *Seja*

$$G(x) = \frac{1}{\sqrt{2\pi}} \int_x^\infty \exp\left(\frac{-y^2}{2}\right) dy.$$

Então, existem constantes $C_1, C_2 > 0$ tais que para todo $x \geq 1$,

$$C_1 \frac{1}{x} \exp\left(\frac{-x^2}{2}\right) \leq G(x) \leq C_2 \frac{1}{x} \exp\left(\frac{-x^2}{2}\right).$$

Em particular, dado $\varepsilon > 0$, temos

$$\lim_{x\to\infty} \frac{G(x+\varepsilon)}{G(x)} = 0.$$

Demonstração. Observe que, fazendo a mudança de variáveis $z = y - x$,

$$\begin{aligned} G(x) = \frac{1}{\sqrt{2\pi}} \int_x^\infty \exp\left(\frac{-y^2}{2}\right) dy &= \frac{1}{\sqrt{2\pi}} \int_0^\infty \exp\left(\frac{-x^2}{2}\right) \exp(-zx) \exp\left(\frac{-z^2}{2}\right) dz \\ &\leq \frac{1}{\sqrt{2\pi}} \exp\left(\frac{-x^2}{2}\right) \int_0^\infty \exp(-zx) dz \\ &= \frac{1}{\sqrt{2\pi}} \frac{1}{x} \exp\left(\frac{-x^2}{2}\right), \end{aligned}$$

provando a desigualdade do lado direito (com $C_2 = (2\pi)^{-1/2}$). Para a desigualdade do lado esquerdo, observe que se $x \geq 1$ e $0 \leq z \leq 2$, então $z^2 \leq 2xz$. Assim,

$$\begin{aligned} G(x) = \frac{1}{\sqrt{2\pi}} \int_x^\infty \exp\left(\frac{-y^2}{2}\right) dy &= \frac{1}{\sqrt{2\pi}} \int_0^\infty \exp\left(\frac{-x^2}{2}\right) \exp(-zx) \exp\left(\frac{-z^2}{2}\right) dz \\ &\geq \frac{1}{\sqrt{2\pi}} \exp\left(\frac{-x^2}{2}\right) \int_0^2 \exp(-2zx) dz \\ &= \frac{1}{\sqrt{2\pi}} \exp\left(\frac{-x^2}{2}\right) \left(-\frac{\exp(-4x)}{2x} + \frac{1}{2x}\right) \\ &\geq \left(\frac{1-e^{-4}}{2\sqrt{2\pi}}\right) \frac{1}{x} \exp\left(\frac{-x^2}{2}\right), \end{aligned}$$

o que prova a desigualdade do lado esquerdo. □

Teorema 28. *Seja $\{X_n\}_{n=1}^\infty$ uma sequência de variáveis aleatórias independentes, com distribuição $N(0, \sigma_n)$. Então, para μ-quase todo ponto,*

$$\limsup_{n\to\infty} \frac{X_n}{\sigma_n \sqrt{2\log n}} = 1 \quad e \quad \liminf_{n\to\infty} \frac{X_n}{\sigma_n \sqrt{2\log n}} = -1.$$

Demonstração. Faremos primeiro a igualdade do lim sup. Podemos supor sem perda de generalidade que $\sigma_n = 1$ para todo n, trocando X_n por X_n/σ_n. Note que, dado $1 > \varepsilon > 0$, para n grande o suficiente (de fato, $n \geq 3$)

$$\begin{aligned} \mathbb{P}\left(X_n \geq (1+\varepsilon)\sqrt{2\log n}\right) &= \mu_{X_n}\left([(1+\varepsilon)\sqrt{2\log n}, \infty)\right) \\ &= \int_{(1+\varepsilon)\sqrt{2\log n}}^\infty \frac{1}{\sqrt{2\pi}} \exp\left(\frac{-y^2}{2}\right) dy \\ &= G\left((1+\varepsilon)\sqrt{2\log n}\right) \\ &\leq C_2 \frac{1}{(1+\varepsilon)\sqrt{2\log n}} \exp\left(-(1+\varepsilon)^2 \log n\right) \\ &< C_2 n^{-1-\varepsilon}. \end{aligned}$$

Também temos, agora para n grande dependendo de ε (por exemplo, tal que $n^{\varepsilon/2} \geq \log n$ e que $(1-\varepsilon)\sqrt{2\log n} \geq 1$)

$$\begin{aligned} \mathbb{P}\left(X_n \geq (1-\varepsilon)\sqrt{2\log n}\right) &= \mu_{X_n}\left([(1-\varepsilon)\sqrt{2\log n}, \infty)\right) \\ &= G\left((1-\varepsilon)\sqrt{2\log n}\right) \\ &\geq C_1 \frac{1}{(1-\varepsilon)\sqrt{2\log n}} \exp\left(-(1-\varepsilon)^2 n\right) \\ &\geq \left(\frac{C_1}{\sqrt{2}(1-\varepsilon)}\right) n^{-1+\varepsilon/2} \left(\frac{n^{\frac{3}{2}\varepsilon - \varepsilon^2}}{\log n}\right) \\ &> C_\varepsilon n^{-1+\varepsilon/2}. \end{aligned}$$

Portanto, fixado um $\varepsilon > 0$ desta forma, temos

$$\sum_{n=1}^{\infty} \mathbb{P}\left(X_n \geq (1+\varepsilon)\sqrt{2\log n}\right) < \infty \quad \text{e} \quad \sum_{n=1}^{\infty} \mathbb{P}\left((1-\varepsilon)\sqrt{2\log n}\right) = \infty.$$

Assim, os lemas de Borel-Cantelli implicam que para quase todo $w \in \Omega$,

$$X_n(w) \leq (1+\varepsilon)\sqrt{2\log n} \text{ para } n \text{ suficientemente grande,}$$
$$X_n(w) \geq (1-\varepsilon)\sqrt{2\log n} \text{ para uma infinidade de valores de } n.$$

Daí concluímos que em quase todo ponto,

$$1-\varepsilon \leq \limsup_{n\to\infty} \frac{X_n}{\sqrt{2\log n}} \leq 1+\varepsilon.$$

Para o $\liminf$, trataremos de $-X_n$ ao invés de X_n. Observe que

$$\begin{aligned}
\mathbb{P}\left(-X_n \geq (1+\varepsilon)\sqrt{2\log n}\right) &= \mathbb{P}\left(X_n \leq -(1+\varepsilon)\sqrt{2\log n}\right) \\
&= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{-(1+\varepsilon)\sqrt{2\log n}} \exp\left(-\frac{y^2}{2}\right) dy \\
&= \frac{1}{\sqrt{2\pi}} \int_{(1+\varepsilon)\sqrt{2\log n}}^{\infty} \exp\left(-\frac{y^2}{2}\right) dy \\
&= G\left((1+\varepsilon)\sqrt{2\log n}\right).
\end{aligned}$$

Da mesma forma, obtemos $\mathbb{P}\left(-X_n \geq (1-\varepsilon)\sqrt{2\log n}\right) = G\left((1-\varepsilon)\sqrt{2\log n}\right)$. Assim, segundo o argumento acima, concluímos que em quase todo ponto,

$$1-\varepsilon \leq \limsup_{n\to\infty} \frac{-X_n}{\sqrt{2\log n}} \leq 1+\varepsilon,$$

ou seja,

$$-1-\varepsilon \leq \liminf_{n\to\infty} \frac{X_n}{\sqrt{2\log n}} \leq -1+\varepsilon,$$

terminando a prova do teorema. □

Fazemos agora algumas desigualdades que serão úteis na prova da lei dos logaritmos iterados.

Lema 29 (Desigualdade de Markov)**.** *Seja X uma variável aleatória que esteja em $L^p(\Omega, d\mu)$, para $1 \leq p < \infty$. Então, para todo $a > 0$,*

$$\mathbb{P}\left(|X| > a\right) \leq \frac{1}{a^p} \|X\|_p^p$$

Observação 30. Em particular, para $p = 1$, temos $\mathbb{P}(|X| > a) \leq \frac{1}{a}\mathbb{E}(|X|)$.

Demonstração. Seja χ a função característica do conjunto $\{w \in \Omega;\ |X(w)| \geq a\}$. Então, $\chi(w)a^p \leq |X(w)|^p$ para todo $w \in \Omega$. Integrando em Ω, obtemos o resultado. □

Teorema 31 (Desigualdade de Lévy)**.** *Sejam $(X_n)_{n=1}^N$ variáveis aleatórias tais que cada X_j tenha uma distribuição par (isto significa que a distribuição de $-X_j$ é a mesma de X_j). Defina $S_j = \sum_{k=1}^{j} X_k$, para $j = 1, \ldots, N$. Então,*

$$\mathbb{P}\left(\max_{j=1,\ldots,N} |S_j| > \alpha\right) \leq 2\mathbb{P}(|S_N| > \alpha).$$

Demonstração. Para cada $j = 1, \ldots, N$, defina o seguinte evento:

$$A_j = \left(\bigcap_{k<j} \{w \in \Omega;\ |S_k(w)| \leq \alpha\} \right) \cap \{w \in \Omega;\ |S_j(w)| > \alpha\}.$$

Considere também a variável aleatória $T_j = S_j - X_{j+1} - \ldots - X_N$. Observe que

$$\left\{ w \in \Omega;\ \max_{j=1,\ldots,N} |S_j| > \alpha \right\} = A_1 \sqcup \ldots \sqcup A_N.$$

Ainda, como $S_N + T_j = 2S_j$, se $w \in \Omega$ for tal que $|S_j(w)| > \alpha$, então $|S_N(w)| > \alpha$ ou $|T_j(w)| > \alpha$, o que implica que

$$A_j = (A_j \cap \{w \in \Omega;\ |T_j| > \alpha\}) \cup (A_j \cap \{w \in \Omega;\ |S_N| > \alpha\}).$$

Portanto, obtemos

$$\begin{aligned} \mathbb{P}\left(\max_{j=1,\ldots,N} |S_j| > \alpha \right) &= \sum_{j=1}^{N} \mathbb{P}(A_j) \\ &\leq \sum_{j=1}^{N} \mathbb{P}\left(A_j \cap \{w \in \Omega;\ |T_j| > \alpha\}\right) + \mathbb{P}\left(A_j \cap \{w \in \Omega;\ |S_N| > \alpha\}\right). \end{aligned}$$

Observe que, ao aplicar a transformação que preserva medida $X_{j+1} \to -X_{j+1}, \ldots, X_N \to -X_N$, não mudamos A_j, e mandamos $\{w \in \Omega;\ |T_j(w)| > \alpha\}$ para $\{w \in \Omega;\ |S_N(w)| > \alpha\}$. Portanto, segue que

$$\mathbb{P}\left(\max_{j=1,\ldots,N} |S_j| > \alpha \right) \leq 2 \sum_{j=1}^{N} \mathbb{P}\left(A_j \cap \{w \in \Omega;\ |S_N(w)| > \alpha\}\right) \leq 2\mathbb{P}\left(|S_N| > \alpha\right).$$

□

Teorema 32 (Desigualdade de Khinchin)**.** *Sejam $(X_n)_{n=1}^N$ variáveis aleatórias i.i.d., com $\mathbb{P}(X_1 = \pm 1) = 1/2$. Seja $S_N = X_1 + \ldots + X_N$. Então,*

(1) $\mathbb{E}\left(e^{\alpha S_N}\right) \leq e^{\alpha^2 N/2}$ *para todo* $\alpha \in \mathbb{R}$.
(2) $\mathbb{P}\left(|S_N| > \beta\right) \leq 2e^{-\beta^2/2N}$, *para todo* $\beta > 0$.

Observação 33. O item (2) desta desigualdade tem a seguinte consequência interessante: se fizermos 50 lançamentos independentes de uma moeda justa (onde colocamos cara como 1 e coroa como -1), e somarmos os resultados obtidos, a probabildade da soma em módulo ser maior que 0.1 é menor que $2e^{-10000}$.

Demonstração. Comecemos com o item (1). Como $\mathbb{P}(X_1 = \pm 1) = 1/2$, a densidade μ_{X_1} é $1/2(\delta_{-1} + \delta_1)$, onde δ_x é a medida de Dirac no ponto x em $\mathbb{R}$. Agora, perceba que se $m \geq 1$ é um número natural, então

$$\frac{(2m)!}{2^m m!} = \frac{(2m)(2m-1)\ldots(m+1)}{2^m} \geq 1$$

pois todos os fatores no numerador são ≥ 2. Assim pelo lema 5,

$$\mathbb{E}\left(e^{\alpha X_1}\right) = \frac{1}{2}e^{\alpha} + \frac{1}{2}e^{-\alpha} = \sum_{m=0}^{\infty} \frac{\alpha^{2m}}{(2m)!} \leq \sum_{m=0}^{\infty} \frac{1}{m!} \left(\frac{\alpha^2}{2}\right)^m = e^{\alpha^2/2}.$$

O item (1) está provado, observando que pela independência e igualdade das distribuições, $\mathbb{E}(e^{\alpha S_N}) = \left(\mathbb{E}(e^{\alpha X_1})\right)^N$.

Para o item (2), observe que pela desigualdade de Markov com $p = 1$ e para todo $\alpha \neq 0$, temos

$$\begin{aligned}\mathbb{P}(|S_N| > \beta) = 2\mathbb{P}(S_N > \beta) &= 2\mathbb{P}\left(e^{\alpha S_N} > e^{\alpha\beta}\right)\\ &\leq 2e^{-\alpha\beta}\mathbb{E}\left(e^{\alpha S_N}\right)\\ &\leq 2e^{-\alpha\beta}e^{\alpha^2 N/2}.\end{aligned}$$

Agora escolhemos um valor de α para minimizar o lado direito desta desigualdade ($\alpha = \beta/N$), e obtemos o resultado. □

Enunciemos agora a lei do logaritmo iterado para um passeio aleatório simples.

Teorema 34 (Lei do logaritmo iterado para um passeio aleatório simples)**.** *Seja $(X_n)_{n=1}^{\infty}$ uma sequência de variáveis aleatórias i.i.d., onde $P(X_1 = \pm 1) = 1/2$. Então, denotando $S_n = X_1 + \ldots + X_n$, temos*

$$\limsup_{n\to\infty} \frac{S_n}{\sqrt{2n\log\log n}} = 1 \quad e \quad \liminf_{n\to\infty} \frac{S_n}{\sqrt{2n\log\log n}} = -1$$

quase sempre.

Observação 35. Suponha que temos um bêbado passeando nos números inteiros, começando do zero, e andando pra direita ou para esquerda com probabilidade igual a 1/2. O que este teorema diz é que, no pior dos casos, o bêbado estará na posição $\pm\sqrt{2n\log\log n}$ no instante n, ou seja, ele consegue ir muito longe, mas com velocidade extremamente pequena (tipo $\sqrt{\log\log}$). Ou seja, mesmo na situação mais extrema de todas, a mãe do bêbado pode dormir tranquila, pois quando ela acordar, conseguirá buscá-lo andando tranquilamente.

Ainda temos que fazer um certo trabalho pra provar este teorema. Primeiro, observamos que só a igualdade do lim sup precisa ser provada (basta substituir X_j por $-X_j$ e obtemos a do lim inf). Nossa estratégia é usar os lemas de Borel-Cantelli para garantir que aquele lim sup é 1 com probabilidade 1. Para isto fazemos a seguinte proposição.

Proposição 36. *Seja $\{X_n\}_{n=1}^{\infty}$ uma sequência de variáveis aleatórias i.i.d., com $\mathbb{P}(X_1 = \pm 1) = 1/2$, e seja $S_N = X_1 + \ldots + X_N$. Então, quase sempre temos*

$$\limsup_{n\to\infty} \frac{|S_n|}{\sqrt{2n\log\log n}} \leq 1.$$

Demonstração. Escolha $\varepsilon > 0$ e $\gamma > 1$. Defina $m_\gamma(n) = \lfloor \gamma^n \rfloor$. Se n for grande o suficiente, então $\lfloor \gamma^n \rfloor \geq \frac{1}{2}\gamma^n$ e portanto, pela desigualdade de Lévy e pela desigualdade

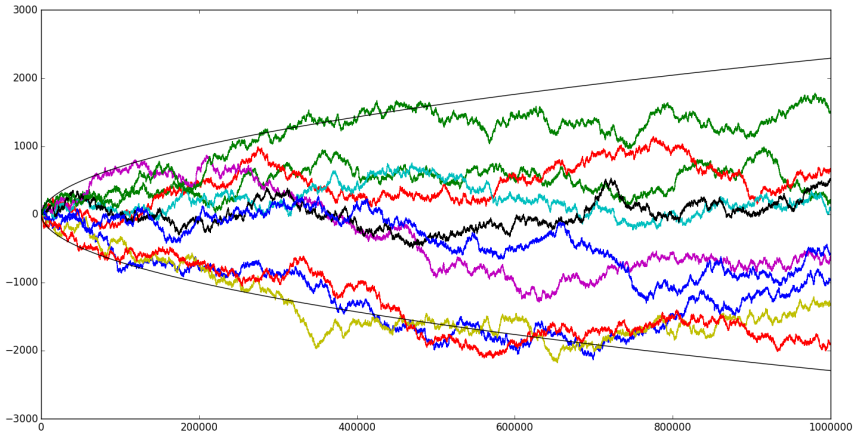

FIGURA 1. Cada linha colorida representa 1000000 de passos de um bêbado, e as linhas pretas representam o gráfico de $\pm\sqrt{2x\log\log x}$. O código do programa em python encontra-se no apêndice.

de Khinchin,

$$\begin{aligned}
&\mathbb{P}\left(\max_{1\le j\le m_\gamma(n)}|S_j|\ge(1+\varepsilon)\sqrt{2m_\gamma(n)\log\log m_\gamma(n)}\right)\\
&\le 2\mathbb{P}\left(|S_{m_\gamma(n)}|\ge(1+\varepsilon)\sqrt{2m_\gamma(n)\log\log m_\gamma(n)}\right)\\
&\le 4\exp\left(-(1+\varepsilon)^2\log\log m_\gamma(n)\right)\\
&\le 4\exp\left(-(1+\varepsilon)^2\log\left(n\log\gamma-\log 2\right)\right)\\
&= 4(n\log\gamma-\log 2)^{-(1+\varepsilon)^2},
\end{aligned}$$

que é somável. Assim, pelo primeiro lema de Borel-Cantelli, segue que

$$\mathbb{P}\left(\limsup\left\{\max_{1\le j\le m_\gamma(n)}|S_j|\ge(1+\varepsilon)\sqrt{2m_\gamma(n)\log\log m_\gamma(n)}\right\}\right)=0,$$

ou seja, em quase todo ponto $w\in\Omega$, existe um inteiro $N_0(w)$ tal que $n\ge N_0(w)$ implica que

$$\max_{m_\gamma(n-1)\le j\le m_\gamma(n)}|S_j(w)|\le\max_{1\le j\le m_\gamma(n)}|S_j(w)|<(1+\varepsilon)\sqrt{2m_\gamma(n)\log\log m_\gamma(n)}.$$

Observe agora que, para todo $\delta>0$, para n suficientemente grande (dependendo de δ)

$$(1-\delta)\gamma=\frac{(1-\delta)\gamma^n}{\gamma^{n-1}}\le\frac{\lfloor\gamma^n\rfloor}{\lfloor\gamma^{n-1}\rfloor}\le\frac{\gamma^n}{(1-\delta)\gamma^{n-1}}=\gamma\left(\frac{1}{1-\delta}\right),$$

o que implica que $\lim_{n\to\infty} \dfrac{m_\gamma(n)}{m_\gamma(n-1)} = 1$. Usando as mesmas estimativas acima, mas com o log,

$$\frac{\log\left(\log(1-\delta)+n\log\gamma\right)}{\log((n-1)\log\gamma)} \leq \frac{\log\log\lfloor\gamma^n\rfloor}{\log\log\lfloor\gamma^{n-1}\rfloor} \leq \frac{\log(n\log\gamma)}{\log\left(\log(1-\delta)+(n-1)\log\gamma\right)},$$

o que mostra que $\lim_{n\to\infty} \frac{\log\log m_\gamma(n)}{\log\log m_\gamma(n-1)} = 1$. Assim, obtemos

$$\lim_{n\to\infty} \frac{\sqrt{2m_\gamma(n)\log\log m_\gamma(n)}}{\sqrt{2m_\gamma(n-1)\log\log m_\gamma(n-1)}} = \gamma^{1/2}.$$

Dado j qualquer, existe n tal que $m_\gamma(n-1) \leq j \leq m_\gamma(n)$. Observando que a função $\sqrt{2m_\gamma(n)\log\log m_\gamma(n)}$ é não-decrescente em n, segue que

$$\frac{|S_j|}{\sqrt{2j\log\log j}} \leq \frac{\max_{m_\gamma(n-1)\leq k\leq m_\gamma(n)}|S_k|}{\sqrt{2m_\gamma(n-1)\log\log m_\gamma(n-1)}} < (1+\varepsilon)\gamma^{1/2}.$$

em quase todo ponto. Escolhendo uma sequência $\varepsilon_k \to 0$ e $\gamma_k \to 1$ e fazendo intersecção destes conjuntos de medida total, obtemos

$$\limsup_{n\to\infty} \frac{|S_n|}{\sqrt{2n\log\log n}} \leq 1.$$

□

Precisamos agora de uma cota inferior para $|S_n|(2n\log\log n)^{-1}$. Para isto, precisaremos da clássica *fórmula de Stirling*, que diz que

$$\frac{n!}{\sqrt{2\pi n}(n/e)^n} = 1 + O\left(\frac{1}{n}\right)$$

quando $n \to \infty$.

Teorema 37 (de Moivre)**.** *Defina*

$$G(n,\alpha(n)) = \frac{2}{\sqrt{2\pi n}}\exp(-2n\alpha(n)^2).$$

Então,

(1) *Então, se $n \to \infty$ e $(1/2+\alpha(n))n \in \mathbb{Z}$, temos*

$$\frac{1}{2^n G(n,\alpha(n))}\binom{n}{(\frac{1}{2}+\alpha(n))n} = 1 + O(n\alpha^3(n)) + O\left(\frac{1}{n}\right) + O(\alpha^2(n)),$$

com convergência uniforme em qualquer região onde $n\alpha^3 \to 0$, $n \to \infty$ e $\alpha(n) \to 0$.

(2) *Sejam $(X_j)_{j=1}^\infty$ sequência de variáveis aleatórias i.i.d, com $\mathbb{P}(X_1 = \pm 1) = 1/2$, $S_N = X_1 + \ldots + X_N$, e*

$$F(a,b) = \frac{1}{\sqrt{2\pi}}\int_a^b \exp\left(\frac{-y^2}{2}\right)dy,$$

que é a probabilidade de uma variável aleatória com distribuição $N(0,1)$ estar no intervalo (a,b). Então,

$$\frac{1}{F(a_N,b_N)}\mathbb{P}\left(\frac{S_N}{\sqrt{N}} \in [a_N,b_N]\right) \longrightarrow 1 \tag{3.1}$$

quando $N \to \infty$, desde que $0 \leq a_N \leq b_N \leq a_N + c$ para algum $c > 0$, e a_N e b_N sejam $o(N^{1/6})$.

Observação 38. Observe que o item 2 do teorema 37 com $a_N = a < b = b_N$ *fixos* (sem depender de N) nos dá o teorema central do limite no caso em que as variáveis aleatórias são estes lançamentos de Bernoulli.

Demonstração. Comecemos com o item (1). Observe que, se $|\alpha(n)| \leq d < \frac{1}{2}$ (que é válido para n grande pelas hipóteses), temos

$$\log\left(2^{-n-1}(2\pi n)^{1/2}\binom{n}{(1/2+\alpha(n))n}\right) = (-n-1)\log 2 + \frac{1}{2}\log(2\pi n) + \\ + \log n! - \log\left((1/2+\alpha(n))n\right)! - \log\left((1/2-\alpha(n))n\right)!.$$

Pela fórmula de Stirling, temos

- $\log n! = \log\left(\sqrt{2\pi n}\left(\frac{n}{e}\right)^n\left(1+O\left(\frac{1}{n}\right)\right)\right)$. Assim, obtemos a expansão
$$\log n! = \log\left(1+O\left(\frac{1}{n}\right)\right) + \frac{1}{2}\log(2\pi n) + n\log n - n,$$
e, usando que $\log(1+x) = x + O(x^2)$ para $x \to 0$, temos $\log(1+O(1/n)) = O(1/n)$, e portanto
$$\log n! = \frac{1}{2}\log(2\pi n) + n\log n - n + O\left(\frac{1}{n}\right),$$
para $n \to \infty$.
- Aplicando o mesmo raciocínio para $(1/2 \pm \alpha(n))n!$ (que é inteiro), obtemos a expansão (notando que $|\alpha| \leq d < 1/2$)
$$\log(1/2 \pm \alpha(n))n! = \frac{1}{2}\log(\pi(1\pm 2\alpha)n) + \left(\frac{1}{2} \pm \alpha(n)\right) n \log\frac{(1\pm 2\alpha(n))n}{2} - \\ - \left(\frac{1}{2} \pm \alpha(n)\right) n + O\left(\frac{1}{n}\right)$$
quando $n \to \infty$.

Substituindo estas expansões na fórmula inicial, obtemos (a partir daqui, escrevemos $\alpha(n) = \alpha$)

$$\log\left(2^{-n}2(2\pi n)^{-1/2}\binom{n}{(1/2+\alpha(n))n}\right) = \\ = -\left\{\left(\frac{1}{2}+\alpha\right)n + \frac{1}{2}\right\}\log(1+2\alpha) - \left\{\left(\frac{1}{2}-\alpha\right)n + \frac{1}{2}\right\}\log(1-2\alpha) + O\left(\frac{1}{n}\right).$$

Da expansão $\log(1+x) = x + O(x^2)$, obtemos

$$\frac{1}{2}\log(1+2\alpha) + \frac{1}{2}\log(1-2\alpha) = O(\alpha^2)$$

quando $\alpha \to 0$. Assim, ficamos com

$$\log\left(2^{-n}2(2\pi n)^{-1/2}\binom{n}{(1/2+\alpha(n))n}\right) = \\ = -\left\{\left(\frac{1}{2}+\alpha\right)n\right\}\log(1+2\alpha) - \left\{\left(\frac{1}{2}-\alpha\right)n\right\}\log(1-2\alpha) + O(\alpha^2) + O\left(\frac{1}{n}\right).$$

Para os termos restantes, precisamos usar a expansão do logaritmo até ordem 3 (i.e., $\log(1+x) = x - \frac{x^2}{2} + O(x^3)$ quando $x \to 0$). Fazendo isto, obtemos finalmente

$$\begin{aligned}\log\left(2^{-n}2(2\pi n)^{-1/2}\binom{n}{(1/2+\alpha(n))n}\right) &= -n\left(2\alpha^2 + O(\alpha^3)\right) + O(\alpha^2) + O\left(\frac{1}{n}\right)\\ &= -2\alpha^2 n + O(n\alpha^3) + O(\alpha^2) + O\left(\frac{1}{n}\right).\end{aligned}$$

Observando que $-2\alpha^2 n = \log(\exp(-2\alpha^2 n))$, temos

$$\log\left(\frac{1}{2^n G(n,\alpha)}\binom{n}{(1/2+\alpha)n}\right) = O(n\alpha^3) + O(\alpha^2) + O\left(\frac{1}{n}\right).$$

Como $|e^x - 1| \leq C|x|$ para x numa vizinhança da origem, obtemos o resultado.

Para o segundo item, provemos inicialmente a seguinte afirmação:
Afirmação: Seja $h : \mathbb{R} \to \mathbb{R}$ uma função não-negativa e não-crescente (ou seja, $x \leq y \implies h(x) \geq h(y)$). Então, para qualquer $\delta > 0$ e $m \geq 1$ inteiro,

$$\left|\int_0^{m\delta} h(y)dy - \sum_{j=0}^{m-1} \delta h(j\delta)\right| \leq \delta h(0).$$

Prova da afirmação: Escrevemos

$$\int_0^{m\delta} h(y)dy = \sum_{j=0}^{m-1} \int_{j\delta}^{(j+1)\delta} h(y)dy.$$

Observe também que como h é não-crescente, se $y \in [j\delta, (j+1)\delta]$, então vale que $|h(y) - h(j\delta)| \leq h(j\delta) - h((j+1)\delta)$. Assim, temos

$$\begin{aligned}\left|\int_0^{m\delta} h(y)dy - \sum_{j=0}^{m-1} \delta h(j\delta)\right| &= \left|\sum_{j=0}^{m-1} \int_{j\delta}^{(j+1)\delta} \left(h(y) - h(j\delta)\right) dy\right|\\ &\leq \sum_{j=0}^{m-1} \delta(h\left(j\delta\right) - h((j+1)\delta))\\ &\leq \delta h(0) - \delta h(m\delta)\\ &\leq \delta h(0),\end{aligned}$$

o que prova a afirmação. ■

Note que se $S_N = X_1 + \ldots + X_N = j$, devemos ter k destes termos iguais a 1 e $N-k$ iguais a -1, onde

$$N - (N-k) = j,$$

ou seja, $k = \frac{1}{2}N + \frac{1}{2}j$. Vamos usar a fórmula do primeiro item. Primeiro, vamos calcular

$$\mathbb{P}\left(\frac{S_N}{\sqrt{N}} \in [a_N, b_N]\right).$$

Note que S_N tem distribuição binomial com parâmetros N e $1/2$, mas como estamos somando ± 1 ao invés de $\{0,1\}$, os valores possíveis são $-N, -N+2, \ldots, N-2, N$.

Assim, denotando o conjunto $\{-N, -N+2, \dots, N-2, N\}$ por $[N]$, temos

$$\begin{aligned}\mathbb{P}\left(\frac{S_N}{\sqrt{N}} \in [a_N, b_N]\right) &= \sum_{j \in [\sqrt{N}a_N, \sqrt{N}b_N] \cap [N]} \mathbb{P}(S_N = j) \\ &= 2^{-N} \sum_{j \in [\sqrt{N}a_N, \sqrt{N}b_N] \cap [N]} \binom{N}{\frac{N}{2} + \frac{j}{2}} \\ &= 2^{-N} \sum_{j \in [\sqrt{N}a_N, \sqrt{N}b_N] \cap [N]} \binom{N}{(1/2 + j/2N)N},\end{aligned}$$

Pelo item anterior, temos (escrevendo $j/2N = \alpha_{j,N}$)

$$2^{-N}\binom{N}{(1/2+\alpha_{j,N})N} = \frac{2}{\sqrt{2\pi N}} e^{-\frac{j^2}{2N}} \left(1 + O\left(\frac{j^3}{N^2}\right) + O\left(\frac{1}{N}\right) + O\left(\frac{j^2}{N^2}\right)\right).$$

Agora, fazemos

$$\begin{aligned}&\left|\mathbb{P}\left(\frac{S_N}{\sqrt{N}} \in [a_N, b_N]\right) - F(a_N, b_N)\right| \\ =&\left|\sum_{j \in [\sqrt{N}a_N, \sqrt{N}b_N] \cap [N]} \frac{2}{\sqrt{2\pi N}} e^{-\frac{j^2}{2N}} \left(1 + O\left(\frac{j^3}{N^2}\right) + O\left(\frac{1}{N}\right) + O\left(\frac{j^2}{N^2}\right)\right) - \frac{1}{\sqrt{2\pi}} \int_{a_N}^{b_N} \exp\left(-\frac{y^2}{2}\right) dy\right| \\ =&\Bigg|\sum_{j \in [\sqrt{N}a_N, \sqrt{N}b_N] \cap [N]} \frac{2}{\sqrt{2\pi N}} e^{-\frac{j^2}{2N}} \left(1 + O\left(\frac{j^3}{N^2}\right) + O\left(\frac{1}{N}\right) + O\left(\frac{j^2}{N^2}\right)\right) - \\ &-\frac{e^{-a_N^2/2}}{\sqrt{2\pi N}} \int_0^{(b_N - a_N)\sqrt{N}} \exp\left(\frac{-y^2}{2N}\right) \exp(-y\sqrt{N}a_N) dy\Bigg| \\ &\leq \frac{C}{\sqrt{N}} \exp\left(-\frac{a_N^2}{2}\right)\end{aligned}$$

quando $N \to \infty$. Assim, para obter o resultado, precisamos que

$$\frac{N^{-1/2}\exp(-a_N^2/2)}{F(a_N, b_N)} \to 0$$

quando $N \to \infty$. Mas como $a_N - b_N \geq c$, $e^{-a_N^2/2}(F(a_N, b_N))^{-1}$ é limitado, e terminamos a prova. □

4. Funções características e Teorema do Limite Central

Nesta seção, nosso objetivo é mostrar que se $\{X_n\}_{n \in N}$ é uma sequência de variáveis aleatórias i.i.d, com $\mathbb{E}(X_1) = \mu$, $\mathbb{V}(X_1^2) = \sigma^2 < \infty$, então

$$\frac{S_n - n\mu}{\sqrt{n}} \to N(0, \sigma).$$

Teorema 39. *Seja $\{X_\alpha\}_{\alpha \in I}$ uma família de variáveis aleatórias tight. Então a família de funções características $\{\phi_{X_\alpha}(t)\}_{\alpha \in I}$ é uma família uniformemente equicontínua e uniformemente limitada de funções em $C(\mathbb{R})$.*

Demonstração. Como a família de variáveis aleatórias é tight, dado $\varepsilon > 0$, tome $R \in \mathbb{R}$ de tal forma que

$$\mathbb{P}(|X_\alpha| > R) \leq \varepsilon/3.$$

Defina A_α a função característica do conjunto mensurável $\{\omega \in \Omega \mid |X_\alpha(\omega)| > \mathbb{R}\}$. Então se $|t-s| < \varepsilon/3R$, temos que

$$\begin{aligned}
|\phi_\alpha(t) - \phi_\alpha(s)| &= |\mathbb{E}(e^{itX_\alpha} - e^{isX_\alpha})| \leq \mathbb{E}(|e^{itX_\alpha} - e^{isX_\alpha}|) \\
&= \mathbb{E}(|e^{itX_\alpha} - e^{isX_\alpha}|A_\alpha) + \mathbb{E}(|e^{itX_\alpha} - e^{isX_\alpha}|(1-A_\alpha)) \\
&\leq \int_{A_\alpha} |e^{itX_\alpha} - e^{isX_\alpha}| d\mu + \int_{X \setminus A_\alpha} \left| \int_s^t iX_\alpha e^{iX_\alpha u} du \right| d\mu \\
&\leq 2\mathbb{P}(|X_\alpha| > R) + R|t-s| < \varepsilon
\end{aligned}$$

Logo, a família é uniformemente equicontínua. Note que a família é uniformemente limitada já que $|\phi_{X_\alpha}(t)| \leq 1$ para todo $t \in \mathbb{R}, \alpha \in I$.

□

Teorema 40 (Teorema de Convergência de Levi - Primeira Forma)**.** *Seja $\{Y_n\}_{n\in\mathbb{N}}$ e Y_∞ uma sequência de variáveis aleatórias com funções características $\phi_n(t) = \mathbb{E}(e^{itY_n})$. Então são equivalentes:*

(1) $Y_n \xrightarrow{d} Y_\infty$
(2) $\phi_n(t) \to \phi_\infty(t)$ *para todo* $t \in \mathbb{R}$
(3) $\phi_n(t) \to \phi_\infty(t)$ *uniformemente para todo intervalo limitado em* $\mathbb{R}$.

Demonstração. (1) implica (2): Fixe $t \in \mathbb{R}$. Pelo Teorema de Prokhorov, a sequência $\{Y_n\}_{n\in\mathbb{N}\cup\{\infty\}}$ é tight, já que suas respectivas distribuições possui fecho compacto. Portanto, dado $\varepsilon > 0$, considere $R > 0$ tal que $\mathbb{P}(|X_n| > R) \leq \varepsilon/2$.
Definindo a função contínua f tal que $f(x) = e^{ixt}$ em $[R, R]$, $f(x) = 0$ em $\Omega \setminus [-R-1, R+1]$ e linear no resto, temos que

$$|\mathbb{E}(e^{itX} - f(X))| \leq \mathbb{E}(|e^{itX} - f(X)|) \leq \int_{\{|X|>R\}} |e^{itX(w)}| d\mu(w) \leq \mathbb{P}(|X| > R).$$

Portanto,

$$\limsup |\phi_n(t) - \phi_\infty(t)| \leq \limsup(|\phi_n(t) - \mathbb{E}(F(X))| + |\phi_n(t) - \mathbb{E}(F(X))) \leq \varepsilon$$

(2) implica (1): Pela Observação 1, se $f \in L^1$, utilizando o teorema da convergência dominada e o fato de que $|\phi_{X_\alpha}(t)| \leq 1$ para todo $t \in \mathbb{R}$, temos que $\mathbb{E}(f(Y_n)) \to \mathbb{E}(f(Y_\infty))$. Agora basta utilizar um argumento de aproximação por funções em L^1 e o resultado vale para funções contínuas de suporte compacto, concluindo assim que a sequência converge em distribuição.

(3) implica (2): Óbvio.

(2) implica (3): Por Prokhorov, temos que $\{Y_n\}_{n\in\mathbb{N}\cup\{\infty\}}$ é tight. Agora, pelo Teorema 39, temos que a sequência das respectivas funções características é uniformemente equicontínua e uniformemente limitada. Agora, restringindo a família de funções características em intervalos compactos da reta, por Arzelà-Ascoli, temos que $\phi_n(t) \to \phi_\infty(t)$ uniformemente.

□

Com essas ferramentas em mãos, conseguimos provar uma nova versão da Lei fraca dos grandes números para uma sequência de variáveis aleatórias i.i.d, mas desta vez com $\mathbb{E}(X_1) < \infty$ e convergência em distribuição.

Teorema 41 (Lei fraca dos grandes números)**.** *Seja $(X_n)_{n=1}^\infty$ uma sequência de variáveis aleatórias i.i.d, e suponha que $\mathbb{E}(X_1) < \infty$. Então,*

$$\frac{S_n}{n} \xrightarrow{d} \mathbb{E}(X_1).$$

Demonstração. Pela Proposição 1, temos que ϕ_{X_1} é C^1 e $\phi'_{X_1}(0) = i\mathbb{E}(X_1)$. Pelo Teorema do valor médio, temos que

$$\phi_{X_1}(t) - \phi_{X_1}(0) = t\phi'_{X_1}(s(t))$$

onde $|s(t)| \leq |t|$. Então, temos que

$$\phi_{X_1}(t) = 1 + i\mathbb{E}(X_1) + o(t),$$

logo, para t pequeno, temos que $\mathrm{Re}(\phi_{X_1}) > 0$. Portanto, tomando um ramo apropriado do logaritmo,

$$\lim_{n\to\infty} n \log \phi_{X_1}(t/n) = \lim_{n\to\infty} n \left[\frac{it}{n}\mathbb{E}(X_1) + O(t/n) + O(t/n)^2\right] = it\mathbb{E}(X_1).$$

Note que, considerando $g(x) = e^{itx}$, como as variáveis aleatórias são i.i.d, temos

$$\phi_{X_j}(t) = \int_\Omega (g \circ X_j) d\mu = \int_{\mathbb{R}} g d\mu_{X_j} = \int_{\mathbb{R}} g d\mu_{X_1}$$

portanto

$$\phi_{S_n/n}(t) = \mathbb{E}(e^{itS_n/n}) = \phi_{X_1}(t/n)^n \to e^{it\mathbb{E}(X_1)} = \phi_{X_\infty}(t).$$

E portanto, pelo Teorema de Convergência de Levi, temos o resultado por (2) implica (1). □

Agora vamos provar o principal resultado da seção:

Teorema 42 (Teorema do Limite Central)**.** *Seja $(X_n)_{n=1}^\infty$ uma sequência de variáveis aleatórias i.i.d, e suponha que $\sigma^2 = \mathbb{E}(X_1^2) < \infty$ e $\mu = \mathbb{E}(X_1)$. Seja X_∞ uma variável aleatória com distribuição normal $N(0,1)$, então*

$$\frac{\sum_{j=1}^n X_j - \mu n}{\sigma\sqrt{n}} \xrightarrow{d} X_\infty$$

Demonstração. Trocando X_j por $X_j + \mu$, podemos supor que $\mu = 0$. Novamente pela Proposição 1, temos que ϕ_{X_1} é C^2 e

$$\phi_{X_1}(t) = 1 - \frac{t^2\sigma}{2} + o(t^2),$$

então, utilizando a mesma ideia da prova anterior da Lei fraca dos grandes números, temos que

$$\begin{aligned}\mathbb{E}(e^{it\sum_{j=1}^n X_j/\sigma\sqrt{n}}) &= \mathbb{E}(e^{itX_1/\sigma\sqrt{n}})^n = \mathbb{E}(1 + itX_1/\sigma\sqrt{n} + \frac{(itX_1/\sigma^2\sqrt{n})^2}{2!} + o(t^2/n))^n \\ &= (1 + 0 - t^2/2n + o(t^2/n))^n \longrightarrow e^{-t^2/2} = \mathbb{E}(e^{itX_\infty}).\end{aligned}$$

E novamente, temos o resultado pelo Teorema de Convergência de Levi.

□

5. Movimento Browniano

O movimento Browniano é, essencialmente, um processo Gaussiano $\{b(s)\}_{s\geq 0}$ indexado pelo intervalo $[0, \infty)$, com covariância dada por

$$\mathbb{E}(b(s)b(t)) = \min(s, t).$$

O bacana é que temos um processo indexado por uma variável contínua! A continuidade da função $\min(s, t)$ vai implicar que o espaço de Hilbert que define este processo é separável, e não teremos problemas para lidar com funções em L^2. Pontualmente, vamos provar que a função $b(s)(w)$ é contínua em s para quase todo w, o que nos permitirá definir uma função aleatória em $C([0, \infty))$.

Antes, vamos motivar a aparição daquele $\min(s, t)$. Considere uma sequência $(x_n)_{n=1}^\infty$ de variáveis aleatórias independentes, cada uma assumindo o valor ± 1 com probabilidade $1/2$ (ou seja, $x_n = \pi_n : \{-1, 1\}^{\mathbb{N}} \to \{\pm 1\}$, onde π_n é a projeção no n-ésimo fator, e $\{-1, 1\}^{\mathbb{N}}$ tem a medida produto). Note que $x_j = \chi_{E_{1,j}} - \chi_{E_{-1,j}}$, onde $E_{\pm 1,j} = \pi_j^{-1}\{\pm 1\}$. Defina então

$$S_n = \sum_{i=1}^n x_j,$$

que é um *passeio aleatório simples*. Note que a covariância entre S_n e S_m é

$$\begin{aligned}\mathrm{Cov}(S_n, S_m) = \mathbb{E}(S_n S_m) &= \int_{\{-1,1\}^{\mathbb{N}}} \left(\sum_{i=1}^n x_i\right)\left(\sum_{j=1}^m x_j\right) d\mu \\ &= \sum_{i=1}^n \sum_{j=1}^m \int_{\{-1,1\}^{\mathbb{N}}} x_i x_j d\mu \\ &= \sum_{i=1}^n \sum_{j=1}^m \int_{\{-1,1\}^{\mathbb{N}}} \left(\chi_{E_{1,i}\cap E_{1,j}} - \chi_{E_{1,i}\cap E_{-1,j}} - \chi_{E_{-1,i}\cap E_{1,j}} + \chi_{E_{-1,i}\cap E_{-1,j}}\right) d\mu \\ &= \min(m, n),\end{aligned}$$

pois os únicos termos não nulos naquela soma são os em que $i = j$. Pelo teorema do limite central, $S_n/\sqrt{n}$ converge em distribuição para uma Gaussiana $N(0, 1)$. Note que

segue que

$$\mathbb{E}\left(\left(\frac{S_{\lfloor ns\rfloor}}{\sqrt{n}}\right)\left(\frac{S_{\lfloor nt\rfloor}}{\sqrt{n}}\right)\right) = \min\left(\frac{\lfloor ns\rfloor}{n}, \frac{\lfloor nt\rfloor}{n}\right),$$

onde $s, t > 0$. Como $\lfloor ns\rfloor/n \to s$ quando $n \to \infty$, faz sentido que $b(s)$ seja algum tipo de limite de $S_{\lfloor ns\rfloor}/\sqrt{n}$. Vamos tentar formalizar isso agora:

Lema 43. *Fixe $0 = t_0 < t_1 < t_2 < \ldots < t_N$. Então, para qualquer $(c_1, \ldots, c_N) \in \mathbb{R}^N$, vale que*

$$\sum_{i,j=1}^{N} c_i c_j \min(t_i, t_j) \geq 0.$$

Demonstração. Provemos a identidade

$$\sum_{i,j=1}^{N} c_i c_j \min(t_i t_j) = \sum_{k=1}^{N} (t_k - t_{k-1})(c_k + \ldots + c_N)^2. \tag{5.1}$$

De fato, chame o polinômio do lado direito da equação acima de $p(c_1, \ldots, c_N)$. Este é um polinômio homogêneo de grau 2, e pela fórmula de Taylor, vale que

$$p(c_1, \ldots, c_N) = \sum_{i,j=1}^{N} \frac{1}{2!} \frac{\partial^2 p}{\partial c_i \partial c_j}(0) c_i c_j.$$

Calculemos esta derivada. Suponha, sem perda de generalidade, que $i \leq j$. Então,

$$\begin{aligned}
\frac{\partial^2}{\partial c_i \partial c_j}\left(\sum_{k=1}^{N}(t_k - t_{k-1})(c_k + \ldots + c_N)^2\right) &= \frac{\partial}{\partial c_i}\left(\sum_{k=1}^{j} 2(t_k - t_{k-1})(c_k + \ldots + c_N)\right) \\
&= 2\sum_{k=1}^{i}(t_k - t_{k-1}) \\
&= 2t_i \\
&= 2\min(t_i, t_j).
\end{aligned}$$

Substituindo isto na fórmula de Taylor, fica provada a equação 5.1, cujo lado direito é claramente não-negativo. □

Teorema 44. *Seja V o espaço vetorial real gerado pelos elementos $(\delta_t)_{t\in(0,\infty)}$. Defina o produto interno*

$$\left\langle \delta_{t_i}, \delta_{t_j} \right\rangle = \min(t_i, t_j),$$

e estenda linearmente para um produto interno em V. O completamento $\overline{V}$ é um espaço de Hilbert separável.

Demonstração. Seja W o espaço $\mathbb{Q}$-linear gerado por $\{\delta_t\}_{t\in(0,\infty)\cap\mathbb{Q}}$. Afirmamos que W é denso em V (e portanto, denso em $\overline{V}$). Seja $x = \sum_{i=1}^{N} c_i \delta_{t_i}$ um elemento arbitrário de V, com $c_i \in \mathbb{R}$ e ordenamos $t_1 < t_2 < \ldots < t_N$. Dado $\varepsilon > 0$, escolha $d_i, s_i \in \mathbb{Q}$ tais que

$|d_i - c_i| < \varepsilon$ e $|t_i - s_i| < \varepsilon$, onde $0 < s_1 < \ldots < s_N$ e $i = 1, \ldots, N$. Assim,

$$\begin{aligned}
\left\| \sum_{i=1}^{N} c_i \delta_{t_i} - \sum_{i=1}^{N} d_i \delta_{s_i} \right\| &\leq \sum_{i=1}^{N} \|c_i \delta_{t_i} - d_i \delta_{s_i}\| \\
&= \sum_{i=1}^{N} \|c_i \delta_{t_i} - d_i \delta_{t_i} + d_i \delta_{t_i} - c_i \delta_{s_i} + c_i \delta_{s_i} - d_i \delta_{s_i}\| \\
&\leq \sum_{i=1}^{N} |c_i - d_i| \left(\|\delta_{t_i}\| + \|\delta_{s_i} - \delta_{t_i}\| \right) \\
&\leq \sum_{i=1}^{N} \varepsilon \left(\|\delta_{t_i}\| + s_i - 2\min(s_i, t_i) + t_i \right) \\
&\leq \varepsilon \sum_{i=1}^{N} \left(\|\delta_{t_i}\| + \varepsilon \right),
\end{aligned}$$

que fica arbitrariamente pequeno reduzindo ε. Fica provado o resultado. □

Segue então que $L^2([0,1], dx) \simeq V$ como espaços de Hilbert, onde dx é a medida de Lebesgue usual. Denotando por $b(s)$ a função em $L^2[0,1$ correspondente ao elemento $\delta_s \in V$ para $s > 0$, obtemos uma família de variáveis (L^2) aleatórias $\{b(s)\}_{s>0}$ com covariância

$$\mathrm{Cov}(b(s), b(t)) = \min(t, s).$$

Qual a distribuição de $b(s)$?

6. Aplicações

Teorema 45 (Teorema de Aproximação de Weierstrass)**.** *Seja $f : [0,1] \to \mathbb{R}$ uma função contínua. Então para todo $\varepsilon > 0$, existe um polinômio $p : [0,1] \to \mathbb{R}$ tal que*

$$\sup_{x \in [0,1]} |f(x) - p(x)| < \varepsilon.$$

Demonstração para estatísticos: Considere um apostador jogando uma moeda (possivelmente viciada) com probabilidade $x \in [0,1]$ de cara e $1-x$ de coroa. Depois de jogar esta moeda $n \in \mathbb{N}$ vezes, anotamos a quantidade $m \in \mathbb{N}$ de caras, e pagamos ao apostador o valor de $f(m/n)$ reais. Isto nos dá uma variável aleatória de distribuição binomial, que descrevemos agora. Se jogarmos a moeda n vezes (n lançamentos de Bernoulli, ou seja, uma binomial), definimos a variável aleatória

$$\begin{aligned}
X : \{\text{cara}, \text{coroa}\}^n &\to \{0, 1, \ldots, n\} \\
(a_i)_{i=1}^n &\mapsto |\{i \in \{1, \ldots, n\};\ a_i \text{ é coroa}\}|,
\end{aligned}$$

que tem distribuição binomial com parâmetros n e x, e a partir dela, a variável aleatória $\mathrm{Pag} : \{\text{cara}, \text{coroa}\}^n \to \mathbb{R}$ por $\mathrm{Pag}\left((a_i)_{i=1}^n\right) = f\left(X((a_i)_{i=1}^n)/n\right)$.

Observe que Pag ainda é uma binomial, e então o seu ganho esperado, $p_n(x)$, depois de jogar a moeda n vezes é

$$p_n(x) = \sum_{k=0}^{n} f(k/n) \binom{n}{k} x^k (1-x)^{n-k}.$$

É claro que se jogarmos a moeda uma quantidade colossalmente grande N_0 de vezes, esperamos que o número M_0 de caras satisfaça $\dfrac{M_0}{N_0} \approx x$ e portanto

$$p_{N_0}(x) \approx f(x).$$

□

A seguir, vamos apresentar outra demonstração deste fato, porém com mais detalhes.

Definição 46 (Polinômios de Bernstein)**.** Definimos o n-ésimo polinômio de Bernstein B_n como

$$B_n(x) = \sum_{k=0}^{n} B(n,k)(x), \ x \in [0,1]$$

onde

$$B(n,k)(x) = \binom{n}{k} x^k (1-x)^{n-k}.$$

Lema 47. *Para todo $n \in \mathbb{N}$, temos que*

$$B_n(x) = 1.$$

Demonstração. Note que

$$1 = (x + (1-x))^n = \sum_{k=0}^{n} \binom{n}{k} x^k (1-x)^{n-k} = B_n(x).$$

□

Lema 48. *Vale a seguinte desigualdade:*

$$\sum_{k=0}^{n} (k - nx)^2 B(n,k)(x) \leq \frac{n}{4}.$$

Demonstração. Utilizando a mesma ideia da prova da esperança da distribuição binomial, é fácil mostrar que

$$\sum_{k=0}^{n} kB(n,k)(x) = nx$$

e também que

$$\sum_{k=0}^{n} k(k-1)B(n,k)(x) = n(n-1)x^2.$$

Portanto, temos que

$$\begin{aligned}
\sum_{k=0}^{n} (k-nx)^2 B(n,k)(x) &= \sum_{k=0}^{n} \left\{ k(k-1) - (2nx-1)k + n^2x^2 \right\} B(n,k)(x) \\
&= n(n-1)x^2 - (2nx-1)nx + n^2x^2 \\
&= x^2n^2 - nx^2 - 2n^2x^2 + nx + n^2x^2 = -nx^2 + nx \\
&= nx(1-x)
\end{aligned}$$

Agora, qualquer vinicius novelli sabe derivar $x(1-x)$ e igualar a zero e verificar que

$$x(1-x) \leq 1/4, \ x \in [0,1].$$

□

Tendo em vista o lema anterior, dividindo tudo por n^2, temos que

$$\sum_{k=0}^{n} (\frac{k}{n} - x)^2 B(n,k)(x) \leq \frac{1}{4n}.$$

Agora estamos prontos para demonstrarmos o teorema 45 com mais detalhes.

Demonstração para matemáticos: Dado $\varepsilon > 0$, como f é uniformemente contínua em $[0,1]$, existe $\delta > 0$ tal que, para quaisquer $a, b \in [0,1]$ com $|a-b| < \delta$, temos que $|f(a) - f(b)| < \varepsilon/2$, e também existe $M > 0$ tal que $|f(x)| \leq M$ para todo $x \in [0,1]$. Logo, se $Y = \{k \leq n \mid |k/n - x| < \delta\}$, então

$$\begin{aligned}
\left| f(x) - \sum_{k=0}^{n} f(k/n) B(n,k)(x) \right| &= \left| f(x) B_n(x) - \sum_{k=0}^{n} f(k/n) B(n,k)(x) \right| \\
&= \left| \sum_{k=0}^{n} (f(x) - f(k/n)) B(n,k)(x) \right| \\
&\leq \sum_{k=0}^{n} |(f(x) - f(k/n))| \, B(n,k)(x) \\
&\leq \sum_{k \in Y}^{n} |(f(x) - f(k/n))| \, B(n,k)(x) \\
&+ \sum_{k \notin Y}^{n} |(f(x) - f(k/n))| \, B(n,k)(x) \\
&< \varepsilon/2 + \sum_{k \notin Y}^{n} |(f(x) - f(k/n))| \, B(n,k)(x) \\
&\leq \varepsilon/2 + \sum_{k \notin Y}^{n} 2M B(n,k)(x) \\
&\leq \varepsilon/2 + 2M \sum_{k \notin Y}^{n} \frac{1}{\delta^2} \left(\frac{k}{n} - x \right)^2 B(n,k)(x) \\
&\leq \varepsilon/2 + 2M \frac{1}{\delta^2} \frac{1}{4n}
\end{aligned}$$

Portanto, escolhendo n grande o suficiente para que

$$2M\frac{1}{\delta^2}\frac{1}{4n} \leq \varepsilon/2$$

concluímos a demonstração. □

A conexão central entre a função zeta de Riemann e os números primos vem da identidade

$$\zeta(s) := \sum_{n=1}^{\infty} \frac{1}{n^s} = \prod_{p \text{ primo}} (1-p^{-s})^{-1},$$

onde $s > 1$ (de fato, isto vale para $s \in \mathbb{C}$ com $\Re s > 1$, mas fiquemos com $s > 1$). Daremos agora uma prova probabiística deste fato.

Teorema 49 (Produto de Euler probabilístico)**.**

$$\sum_{n=1}^{\infty} \frac{1}{n^s} = \prod_{p \ primo} (1-p^{-s})^{-1},$$

para $s > 1$.

Demonstração. Defina em $\Omega = \mathbb{N}$ a medida de probabilidade (na σ-álgebra discreta) $\mu(\{n\}) = \frac{n^{-s}}{\zeta(s)}$, e considere a variável aleatória

$$X : \Omega \to \mathbb{N}$$

definida por $X(w) = w$, ou seja,

$$\mathbb{P}(X = n) = \frac{n^{-s}}{\zeta(s)}.$$

Considere o evento $E_k := \{w \in \Omega; X(w) \text{ é divisível por } k\}$. Afirmamos que os eventos $\{E_p; p \text{ primo}\}$ são independentes. De fato, precisamos provar que para toda coleção finita de primos p_i distintos, $i = 1, \ldots, n$,

$$\mathbb{P}\left(\bigcap_{i=1}^{n} E_{p_i}\right) = \prod_{i=1}^{n} \mathbb{P}(E_{p_i}).$$

Entretanto, observe que para todo $k \in \mathbb{N}$,

$$\mathbb{P}(E_k) = \sum_{n=1}^{\infty} \frac{(kn)^{-s}}{\zeta(s)} = k^{-s}.$$

Ainda, como um inteiro é divisível por $p_1, p_2, \ldots, p_n$ se, e somente se, for divisível pelo produto $p_1 \cdot \ldots \cdot p_n$, temos

$$\bigcap_{i=1}^{n} E_{p_i} = E_{\prod_{i=1}^{n} p_i}.$$

Assim,

$$\mathbb{P}\left(\bigcap_{i=1}^{n} E_{p_i}\right) = \mathbb{P}\left(E_{\prod_{i=1}^{n} p_i}\right) = p_1^{-s} \ldots p_n^{-s} = \prod_{i=1}^{n} \mathbb{P}(E_{p_i}),$$

provando a independência. Agora, observe que o único inteiro positivo que não é múltiplo de nenhum primo é 1. Assim

$$\frac{1}{\zeta(s)} = \mathbb{P}(X=1) = \mathbb{P}\left(\bigcap_{p \text{ primo}} E_p^c\right) \underbrace{=}_{\text{independência}} = \prod_p (1-p^{-s}).$$

□

7. Códigos dos programas usados

7.0.1. *Randon Walk/Andar do Bêbado - Python.*

```
import random
import matplotlib.pyplot as plt
import numpy as np

random.seed(8)  # caso queira rodar no aleatório, colocar random.seed()

passos = 1000000   # quantidade passos que os bêbados darão
bebados = 1   # quantidade de bêbados

coordX = []
coordY = []

for k in range(0,bebados):
    j=0
    for i in range(3,passos):
        j = j + int(random.randrange(-1,2,2))
        coordY.append(j)
        if k ==0:
            coordX.append(i)

    plt.plot(coordX,coordY)
    coordY.clear()

coordLog = np.sqrt(np.multiply(2.0,np.multiply(coordX,  np.log(np.log(coordX)))))

plt.plot(coordX,  coordLog, 'black')
plt.plot(coordX, -coordLog, 'black')

plt.show()
```